

FAR 核心理论与逐步数学推导

阅读说明：本文从哪里来，保留什么

本文对应 [FAR_ClearGrasp_RGBOnly_DINOv3_H16plus_8x3090_三架构整合研究计划](#)，是一份可以独立阅读的理论展开稿。原计划是研究依据，其中的实施安排不等于已经完成的实验。

保留的主线是：单张 RGB 预测透明物体首表面米制光轴深度；用训练 GT 深度重加权冻结模型的原 attention；先做固定模型关系干预，再通过单层少量 Q/K LoRA 学习；在完全相同 LoRA 的对照下检验 FAR 的增量作用。主骨干仍是 DINOv3 ViT-H/16+，并保留 DPT、U-Net、双分支 U-Net+DPT 三种读出和 B0-B2 / H0-H2 对照。

本文按“任务 → attention → 关系教师 → 干预 → 学生 → 损失与反传 → 能力边界 → 三架构 → 证据要求”组织。变量都在首次使用处解释，不要求预先记忆符号表。原计划的公式编号 G1-X5 保留，新增中间步骤紧邻原公式；末尾给出逐项对应和复核结论。

有三类内容需要区分：

- 定义或设计选择**：例如截断 log-depth 代价、LoRA 秩、三架构融合方式。可以解释选择理由与计算过程，但不能由代数证明其必然最优。
- 可证明的关系**：例如约束优化最优解、概率质量保持、KL 梯度和低秩限制。本文展开每个关键等号和不等号。
- 待验证的研究假设**：例如关系重加权是否降低真实透明深度误差。数学解释不能替代 oracle、普通 LoRA 对照或封存真实测试。

除特别说明外，log 是自然对数；attention 的 token 按行排列，线性权重按“输入通道×输出通道”书写；真实数计算与浮点实现误差分开讨论。本文没有新增 Dice、法线、中间深度监督或推理用 GT。

1. 任务的几何含义：到底预测哪一个深度

1.1 从针孔投影得到像素射线 [G1]

取一个像素 p，图像坐标为 (u,v)。设该像素对应的三维点在相机坐标系中为 (x_p,y_p,z_p)，其中 z_p 是沿相机光轴的坐标。针孔投影定义为

$$u = f_x \frac{x_p}{z_p} + c_x, \quad v = f_y \frac{y_p}{z_p} + c_y.$$

这里 f_x、f_y 是以像素为单位的焦距，c_x、c_y 是主点位置。这是相机模型的假设，不是从 RGB 推断深度的算法。

第一步，分别移项并除以焦距：

$$\frac{x_p}{z_p} = \frac{u - c_x}{f_x}, \quad \frac{y_p}{z_p} = \frac{v - c_y}{f_y}.$$

第二步，把两个比值和第三分量 1 写成向量。用 K_{cam} 表示相机内参矩阵，以 q_p 表示未归一化射线：

$$K_{cam} = \begin{bmatrix} f_x & 0 & c_x \\ 0 & f_y & c_y \\ 0 & 0 & 1 \end{bmatrix}, \quad q_p = K_{cam}^{-1}(u, v, 1)^T = \left(\frac{u - c_x}{f_x}, \frac{v - c_y}{f_y}, 1 \right)^T. \quad (G1)$$

第三步，乘回 z_p ，得到三维点 $X_p = z_p q_p$ 。 q_p 的第三分量恰为 1，所以这里的比例系数就是光轴深度，不是到相机中心的欧氏距离。

1.2 从射线的所有交点定义首表面 [G2]

令 S 表示场景真实表面的集合。像素射线上的点具有 zq_p 的形式，且可见方向要求 $z > 0$ 。射线可能依次经过玻璃前壁、后壁和桌面；将所有命中表面的正深度取最小值：

$$Z_f(p) = \min\{z > 0 : zq_p \in S\}. \quad (G2)$$

这一步是任务标签的定义。严格说，它适用于存在最早正交点的有效射线；无命中、无有效深度范围或数值异常时，该像素应标为无效。

由这个定义可直接解释几个边界情况：

- 杯口射线先命中内壁：内壁可作为首表面。
- 射线真正穿过孔洞而先命中背景：目标就是该背景，不能因位于物体外轮廓内而强标玻璃。
- 前方有遮挡物：首命中是遮挡物。

因此，训练 mask 的语义必须和真实首命中对应，而不能只填满透明物体的二维轮廓。

1.3 射线距离为什么需要除以射线范数 [G3]

如果渲染器输出的是沿单位射线的距离 r_p ，单位方向是 $d_p = q_p / \|q_p\|_2$ 。同一个三维点有两种写法：

$$X_p = r_p d_p = \frac{r_p}{\|q_p\|_2} q_p, \quad X_p = z_p q_p.$$

因为 q_p 不为零，比较相同方向前的系数：

$$z_p = \frac{r_p}{\|q_p\|_2}. \quad (G3)$$

展开范数，还可写成

$$z_p = \frac{r_p}{\sqrt{1 + ((u - c_x)/f_x)^2 + ((v - c_y)/f_y)^2}}.$$

主点处范数为 1，两种深度相等；离主点越远，射线距离一般越大于光轴深度。原计划训练优先使用已发布的 depth-rectified.exr，**不能把 G3 再应用一次**。真实评估按计划使用 opaque-depth-img.exr，透明场景原始传感器深度不自动等于首表面 GT。

1.4 透明成像为何给关系学习带来困难 [G4]

对于像素 p ，令 $I(p)$ 表示观测 RGB， $F(p)$ 表示反射比例， $L_{\text{refl}}(p)$ 表示反射方向带来的辐亮度， $T(p)$ 表示透射路径的衰减。折射把背景读取位置从原像素方向移到 $\pi_{\text{refr}}(p)$ ，对应背景辐亮度为 $L_{\text{bg}}(\pi_{\text{refr}}(p))$ 。

在忽略复杂多次反射、散射与曝光非线性的解释模型中：

1. 入射能量中的反射部分贡献 $F L_{\text{refl}}$ 。
2. 余下比例约为 $1-F$ ，经透射衰减后贡献 $(1-F)T L_{\text{bg}}$ 。
3. 把两部分相加，得到

$$I(p) \approx F(p)L_{\text{refl}}(p) + (1 - F(p))T(p)L_{\text{bg}}(\pi_{\text{refr}}(p)). \quad (\text{G4})$$

这不是完整渲染方程，也不是 FAR 训练中需要求解的物理层。它说明：**像素外观可能主要来自背景，但目标深度属于玻璃首界面**。同时，高光、轮廓和折射也可能提供几何信息，因此不能把所有背景关联或光学变化都删掉。

1.5 RGB-only 和米制深度并不矛盾

RGB-only 约束的是部署输入。训练读取米制深度和透明 mask 是有监督学习。

尺度歧义可以从针孔式直接看出：将三维点和场景尺寸同时乘任意正数 a ，投影中的 $(ax_p)/(az_p)=x_p/z_p$ 不变。因此单张 RGB 一般不能唯一确定任意场景的绝对尺寸。模型学到的米制尺度来自训练数据的距离、物体尺寸与场景先验；正值输出函数不会自行消除这一歧义。

2. FAR 实际作用的变量：ViT 的关系聚合

2.1 先固定真实模型与 token 数

原计划主模型是官方 `dinov3_vith16plus`：32 个 blocks，特征宽度 $C=1280$ ，20 个 heads，patch 边长 16。于是每头宽度 $d=C/20=64$ 。模型保留 1 个 CLS 和 4 个 register/storage tokens。对应配置以原计划锁定的代码版本为准。[官方 Hub 配置](#)

输入画布 384×512 时，沿高宽分别有 $384/16=24$ 、 $512/16=32$ 个 patches，因此

$$N_{\text{patch}} = 24 \times 32 = 768, \quad N = 768 + 1 + 4 = 773.$$

N 是参与 attention 的完整 token 数；输出深度时只把 768 个 patch tokens 还原为空间网格，前缀 tokens 不当成像素。

2.2 LayerNorm 后的 Q、K、V 是怎么来的 [A1]

取被选中的一个 block，令 H 表示它的输入 token 矩阵，大小 $N \times C$ 。先做第一个 LayerNorm，得到 $X = \text{LN}_1(H)$ 。此处 H 是特征，不是输入图像的高度。

为明确 LayerNorm 的含义，对任意一行 h ，令该行通道均值为 μ 、方差为 v ：

$$\mu = \frac{1}{C} \sum_{a=1}^C h_a, \quad v = \frac{1}{C} \sum_{a=1}^C (h_a - \mu)^2, \quad X_a = \gamma_a \frac{h_a - \mu}{\sqrt{v + \epsilon_{\text{LN}}}} + b_a^{\text{LN}}.$$

其中 γ 、 b^{LN} 为原模型归一化参数， ϵ_{LN} 为稳定常数，全部冻结。计算顺序是先减均值，再除标准差，最后逐通道缩放平移。

对某个 head h ，用 $W^0_{\text{Q},h}$ 、 $W^0_{\text{K},h}$ 、 $W^0_{\text{V},h}$ 表示原模型的三个 $C \times d$ 投影。上标 0 表示原始冻结参数与原始关系：

$$Q_h^0 = XW_{Q,h}^0 + b_{Q,h}^0, \quad K_h^0 = XW_{K,h}^0 + b_{K,h}^0, \quad V_h^0 = XW_{V,h}^0 + b_{V,h}^0. \quad (A1)$$

例如第 i 个 query 的第 t 个通道，就是 $\sum_a X_{ia} W_{Q,h}^0 + b_{Q,h}^0$ 。三个结果均为 $N \times d$ 。Q 提供“当前 token 如何查询”，K 提供“其他 token 如何被匹配”，V 提供“实际被汇聚的内容”；它们并不天然分别代表纯几何、纯语义或纯外观。

这里 $b_{K,h}^0$ 指应用有效 bias mask 后的偏置。该 H/16+ 配置的有效 Key bias 为零。官方路径是 packed QKV 后做 RoPE，再执行 SDPA，不包含额外 Q/K normalization。官方 attention 实现

2.3 为什么 RoPE 后的打分必须保留两个位置 [A2]

令 R_i 表示位置 i 对应的正交旋转，满足 $R_i R_i^T = I$ 。实际二维 RoPE 使用多个通道对；本文用一个 $d \times d$ 矩阵统一表示，不把它替换成额外的一维位置编码。前缀 token 在该记号中使用单位变换。

按行向量约定，旋转后的 query、key 为

$$\tilde{q}_i = q_i R_i, \quad \tilde{k}_j = k_j R_j.$$

取内积时，转置会反转乘法顺序：

$$\tilde{q}_i \tilde{k}_j^T = (q_i R_i)(k_j R_j)^T = q_i R_i R_j^T k_j^T.$$

于是第 h 个 head 的原始打分矩阵为

$$S_{h,ij}^0 = \frac{q_{h,i}^0 R_i R_j^T (k_{h,j}^0)^T}{\sqrt{d}}. \quad (A2)$$

除以 $\sqrt{d}$ 的动机是控制点积尺度：若 d 个通道乘积近似独立、各项均值为 0、方差为 1，则点积方差为 d ，除以 $\sqrt{d}$ 后方差为 1。这是尺度分析，不要求训练后的通道严格独立。

LoRA 必须加在旋转前的 Q/K 投影上，教师与学生随后使用相同 RoPE。骨干与 RoPE 保持 eval，关闭计划提到的训练期随机坐标变换，否则“同一 RGB 对应固定原关系”的条件会被破坏。

2.4 softmax 如何把打分变成聚合权重 [A3]

对固定 query i ，把所有 N 个 key 的打分取指数，再除以指数和：

$$A_{h,ij}^0 = \frac{e^{S_{h,ij}^0}}{\sum_{u=1}^N e^{S_{h,iu}^0}}, \quad \sum_{j=1}^N A_{h,ij}^0 = 1, \quad O_h^0 = A_h^0 V_h^0. \quad (A3)$$

行和为 1，是因为分子逐项求和后恰好等于分母；每项非负来自指数非负。矩阵乘法的第 i 行为

$$O_{h,i}^0 = \sum_{j=1}^N A_{h,ij}^0 v_{h,j}^0.$$

因此 O 是 V 内容的加权平均。完整 key 集合包括前缀、普通 patch 和 padding tokens；计划仅排除它们的某些监督角色，没有额外改动骨干 attention 的分母。

数值实现用减去每行最大打分的 softmax。对行常数 t ，有 $\exp(S_{ij}-t)/\sum_u \exp(S_{iu}-t) = \exp(S_{ij})/\sum_u \exp(S_{iu})$ ，因为公共因子 $\exp(-t)$ 抵消。

2.5 多头、输出投影、LayerScale 和残差 [A4]

设 n_h 为该模型的总 head 数。所有 heads 的 O 沿通道拼接，再乘输出矩阵 W_O 。把 W_O 按 head 对应的输入行拆为 $W_{O,h}$ ，利用块矩阵乘法：

$$[O_1, \dots, O_{n_h}]W_O = \sum_h O_h W_{O,h}.$$

令 b_O 表示输出偏置， Γ_1 、 Γ_2 表示两个原 LayerScale 的对角矩阵，MLP 表示前馈子层。第一个残差后的结果记为 U^0 ，整个 block 的结果记为 H_{next}^0 ：

$$U^0 = H + \left[\sum_h A_h^0 V_h^0 W_{O,h} + b_O \right] \Gamma_1, \quad H_{next}^0 = U^0 + MLP(LN_2(U^0)) \Gamma_2. \quad (A4)$$

这两个等号来自网络的实际计算顺序：聚合 → 投影 → 缩放 → 加输入，再对该结果进行第二个归一化与前馈残差。

H/16+ 的 MLP 实际是 SwiGLU。若输入行是 x ，令 $a=xW_1+b_1$ 、 $b=xW_2+b_2$ ，则前馈输出为 $[SiLU(a) \odot b]W_3+b_3$ ，其中 $SiLU(a)=a \odot \sigma(a)$ ， σ 为 sigmoid， $\odot$ 为逐元素乘法。配置先给出 $1280 \times 6=7680$ 的名义宽度，再按 $2/3$ 得到 5120，已满足 8 的倍数对齐。[官方 SwiGLU 实现](#)

FAR 的诊断改动发生在 A，当前 V、W_O、LayerScale 和下游均按原模型计算。 相似 attention 热图不必产生相似深度：实际效果还取决于被读取的 V 和完整下游。

3. 从 GT 深度构造 FAR 教师：逐步求解

3.1 先解决一个 patch 代表什么表面

一个 16×16 patch 可能同时覆盖玻璃、桌面和孔洞。两种表面深度的平均值可能对应一个根本不存在的中间表面。因此教师先选可靠 patch，再计算深度关系。

设一个 patch 中非 padding 的候选像素集合为 V_i ，其中正、有限、位于预定标签范围的像素集合为 V_i^{valid} 。有效覆盖率是 $|V_i^{valid}|/|V_i|$ ；类别纯度是在固定标签有效规则下同类别像素的比例。原计划使用至少 90% 的有效覆盖和类别纯度，并以 $IQR(\log(Z/(1m))) \leq 0.1$ 作为初始深度一致性阈值；IQR 指第 75 百分位减第 25 百分位。除以 1m 表示先把深度变为无量纲米制数值；换一个固定参考单位只会给所有 log 深度加同一常数，不改变 IQR。阈值是待开发集确认的设计参数，具体边界与百分位算法要在实现时固定。

把通过筛选的透明 queries 记为 T，通过筛选的非透明 queries 记为 B，其他混合或无效 queries 记为 U。把能够提供可靠深度代表值的图像 keys 记为 K_{rel} ，它可以包含透明或背景 patches，但排除前缀、padding、无效和混合边界。

对可靠 patch i ，令 $z_i^* > 0$ 为合法像素深度的中位数。这里星号表示 GT。中位数用于降低少数异常值的影响；它仍是 patch 级代表值，不是 patch 内每一个像素的真实深度。

边界仅退出关系监督，其合法像素仍进入深度损失。GT mask 不传入 DINOv3 的 patch masks 参数。

3.2 为什么使用截断的 log-depth 代价 [P1]

对于透明 query i 与可靠 key j ，先定义相对对数差：

$$t_{ij} = \log(z_i^*/z_j^*) = \log \frac{z_i^*}{1/m} - \log \frac{z_j^*}{1/m}.$$

比值使对数自变量无量纲。再用正参数 σ_z 规定多大的相对差异值得明显惩罚，得到平方代价 $t_{ij}^2/(2\sigma_z^2)$ 。这个形式可以由“对相对 log-depth 差使用高斯形状的兼容核”解释：

$$\kappa_{ij} = \exp\left(-\frac{t_{ij}^2}{2\sigma_z^2}\right) \implies -\log \kappa_{ij} = \frac{t_{ij}^2}{2\sigma_z^2}.$$

这里高斯核是兼容性偏好的选择，不是已证明的真实噪声分布。最后使用正上限 $c_{\max}$ 截断，得到计划代价：

$$c_{ij} = \min\left(\frac{[\log(z_i^*/z_j^*)]^2}{2\sigma_z^2}, c_{\max}\right), \quad \sigma_z > 0, \quad c_{\max} > 0. \quad (P1)$$

依次理解：先比较深度比例，再取对数消除正反比例的不对称，再平方非负化，再按容忍宽度缩放，最后限制最大排斥强度。

例如 $z_i^*=0.6m$ 、 $z_j^*=0.9m$ 、 $\sigma_z=0.1$ ，则 $\log(2/3) \approx -0.405465$ ，平方约 0.164402，除以 0.02 约为 8.2201； $c_{\max}=4$ 时最终代价为 4。

整体乘尺度 $a>0$ 时， $\log(az_i^*/az_j^*)=\log(z_i^*/z_j^*)$ ，故此代价尺度不变。**同深度不意味着同一物体，同物体不同位置也可能具有不同深度。**这解释了为何只能温和重加权，并需要后面的 oracle。

3.3 先保存可靠 keys 的总概率质量〔P2〕

以下固定一个 head 和一个 query，暂省略 head 下标。原关系 A_i^0 已经在全部 N 个 keys 上归一化。

先把可靠 keys 上的概率相加，定义总质量 m_i ；再除以该质量，得到可靠集合内部的条件分布 a_i^0 ：

$$m_i = \sum_{j \in K_{rel}} A_{ij}^0, \quad a_{ij}^0 = \frac{A_{ij}^0}{m_i} \quad (j \in K_{rel}). \quad (P2)$$

当 $m_i>0$ 时，

$$\sum_{j \in K_{rel}} a_{ij}^0 = \frac{1}{m_i} \sum_{j \in K_{rel}} A_{ij}^0 = 1.$$

这里 m_i 回答“原模型把多少注意力分给可靠图像 keys”， a_i^0 回答“这些注意力在可靠 keys 内如何分配”。FAR 主教师固定前者，只调整后者。

3.4 把“尽量保留原关系，同时减少不兼容关系”写成优化问题〔P3〕

令 $q=(q_j)$ 表示可靠 keys 内待求的新条件概率。KL 散度定义为

$$D_{KL}(q||a_i^0) = \sum_{j \in K_{rel}} q_j \log \frac{q_j}{a_{ij}^0}.$$

它衡量 q 偏离原条件分布的程度。期望代价是 $\sum_j q_j c_{ij}$ ：把更多概率放给高代价 key 就会增加该项。

将两项相加，在概率单纯形上求最小值：

$$q_i^* = \arg \min_{q_j \geq 0, \sum_j q_j = 1} \left[D_{KL}(q||a_i^0) + \sum_j q_j c_{ij} \right]. \quad (P3)$$

KL 项的系数在本计划中为 1；代价尺度由 σ_z 与 $c_{\max}$ 控制。额外写一个温度并独立调参会改变原计划的超参数设计，因此本文不悄悄加入它。

3.5 拉格朗日求导：每一步得到指数重加权 [P4-P5]

先假设 $a_{ij}^0 > 0$ 、代价有限且 K_{rel} 非空。这在数学上的有限 logits softmax 下成立。令 ν 为归一化约束的拉格朗日乘子，写出

$$\mathcal{J}(q, \nu) = \sum_j q_j \log \frac{q_j}{a_{ij}^0} + \sum_j q_j c_{ij} + \nu \left(\sum_j q_j - 1 \right).$$

对第 j 项，先将 $q_j \log(q_j/a_{ij}^0)$ 拆为 $q_j \log q_j - q_j \log a_{ij}^0$ 。因为 a_{ij}^0 是常量，

$$\frac{\partial(q_j \log q_j)}{\partial q_j} = \log q_j + 1, \quad \frac{\partial(-q_j \log a_{ij}^0)}{\partial q_j} = -\log a_{ij}^0.$$

线性代价项导数为 c_{ij} ，约束项导数为 ν ，合起来：

$$\frac{\partial \mathcal{J}}{\partial q_j} = \log \frac{q_j}{a_{ij}^0} + 1 + c_{ij} + \nu = 0. \quad (\text{P4})$$

依次移项、取指数：

$$\log \frac{q_j}{a_{ij}^0} = -1 - \nu - c_{ij} \implies q_j = a_{ij}^0 e^{-c_{ij}} e^{-1-\nu}.$$

对 j 求和并使用 $\sum_j q_j = 1$ ：

$$1 = e^{-1-\nu} \sum_j a_{ij}^0 e^{-c_{ij}}.$$

定义 $Z_i^{\text{norm}} = \sum_k a_{ik}^0 e^{-c_{ik}}$ ，于是 $e^{-(1+\nu)} = 1/Z_i^{\text{norm}}$ ，代回：

$$q_{ij}^* = \frac{a_{ij}^0 e^{-c_{ij}}}{Z_i^{\text{norm}}}, \quad Z_i^{\text{norm}} = \sum_{k \in K_{\text{rel}}} a_{ik}^0 e^{-c_{ik}}. \quad (\text{P5})$$

Z_i^{norm} 是归一化常数，不是深度。含义是：原条件概率乘以兼容系数，再重新归一化。代价相等的两个 keys 保留原概率比；代价较大的 key 被相对降权。

3.6 为什么驻点确实是唯一全局最优解 [P6]

由 P5 直接取对数：

$$\log q_{ij}^* = \log a_{ij}^0 - c_{ij} - \log Z_i^{\text{norm}}.$$

把它代入 $D_{\text{KL}}(q \| q_i^*)$ ：

$$\begin{aligned} D_{\text{KL}}(q \| q_i^*) &= \sum_j q_j (\log q_j - \log a_{ij}^0 + c_{ij} + \log Z_i^{\text{norm}}) \\ &= D_{\text{KL}}(q \| a_i^0) + \sum_j q_j c_{ij} + \log Z_i^{\text{norm}} \sum_j q_j \\ &= D_{\text{KL}}(q \| a_i^0) + \mathbb{E}_q[c] + \log Z_i^{\text{norm}}. \end{aligned}$$

最后一行使用 $\sum q_j = 1$ 。移项即得到

$$D_{\text{KL}}(q \| a_i^0) + \mathbb{E}_q[c] = D_{\text{KL}}(q \| q_i^*) - \log Z_i^{\text{norm}}. \quad (\text{P6})$$

再解释 KL 为什么非负：对 $t>0$ ，有 $\log t \leq t-1$ 。取 $t=q_j^*/q_j$ ，乘 $-q_j$ 并求和，得到

$$\sum_j q_j \log \frac{q_j}{q_j^*} \geq \sum_j (q_j - q_j^*) = 0,$$

零项按连续极限解释。等号只在两个分布相同时成立。因此右边在 $q=q_j^*$ 处最小，且正支持下唯一。也可查看 Hessian：对 q 的二阶导为 $\text{diag}(1/q_j)$ ，任意非零方向的二次型 $\sum_j v_j^2/q_j > 0$ ，因此目标严格凸。

一个补充结论来自把 $q=a_i^0$ 作为可行比较：

$$D_{KL}(q_i^* \| a_i^0) + \mathbb{E}_{q_i^*}[c] \leq \mathbb{E}_{a_i^0}[c] \implies \mathbb{E}_{q_i^*}[c] \leq \mathbb{E}_{a_i^0}[c].$$

这仅证明**所设计代价**不会增加，不证明真实深度误差下降。

3.7 恢复完整分布，再做温和混合 [P7]

q_j^* 只在可靠 keys 内定义。先乘回原总质量 m_i ，补集保持每个原概率，得到完整候选 G_i ：

$$G_{ij} = \begin{cases} m_i q_{ij}^*, & j \in K_{rel}, \\ A_{ij}^0, & j \notin K_{rel}. \end{cases}$$

再引入混合强度 $\beta \in [0,1]$ 。透明可靠 query 采用原关系与 G 的凸组合，其他 query 保留原关系：

$$P_i = \begin{cases} (1-\beta)A_i^0 + \beta G_i, & i \in T, \\ A_i^0, & i \notin T. \end{cases} \quad (P7)$$

P 是最终教师目标。 β 由离线选择和独立确认后锁定，测试时不能借助 GT 为每张图再调 β 。

逐项检查：

1. G 的可靠部分行和为 $m_i \sum q_{ij}^* = m_i$ ，补集行和为 $1-m_i$ ，故总和为 1。
2. P 是两个合法分布的非负凸组合，所以非负且行和为 $(1-\beta)+\beta=1$ 。
3. 补集内 $P_{ij}=(1-\beta)A_{ij}^0+\beta A_{ij}^0=A_{ij}^0$ ，逐项保持。
4. 可靠集合质量为 $(1-\beta)m_i+\beta m_i=m_i$ ，整体保持。
5. $\beta=0$ 恢复原关系；若代价在该行可靠集合内为任意常数，指数因子在 P5 分子分母抵消，也恢复原关系。
 $c \equiv 0$ 是这个结论的特例。

K_{rel} 为空、 m_i 低于数值阈值或计算非有限时，整行回退到 A_i^0 。数学上严格正的概率也可能在低精度下下溢，因此该保护不能省略。

3.8 “温和”到底能保证什么 [P8]

对于可靠 key，用 P5 消去条件概率：

$$G_{ij} = m_i \frac{(A_{ij}^0/m_i)e^{-c_{ij}}}{Z_i^{norm}} = A_{ij}^0 \frac{e^{-c_{ij}}}{Z_i^{norm}}.$$

所以

$$P_{ij} = A_{ij}^0 \left(1 - \beta + \beta \frac{e^{-c_{ij}}}{Z_i^{norm}} \right).$$

由于 $0 \leq c_{ij} \leq c_{\max}$ ，有 $e^{(-c_{ij})} \geq e^{(-c_{\max})}$ 。同时 $e^{(-c_{ij})} \leq 1$ ，因此 $Z_i^{\text{norm}} \leq \sum_j a_{ij}^0 = 1$ 。分母不大于 1，进一步得到

$$P_{ij} \geq (1 - \beta + \beta e^{-c_{\max}}) A_{ij}^0. \quad (\text{P8})$$

例如 $\beta=0.5$ 、 $c_{\max}=4$ ，下界系数约为 0.509158。它限制的是教师对可靠 key 原概率的最大相对削弱，不代表背景预测误差一定无损。

还可以推导整体改动量。定义总变差距离 $TV(P_i, A_i^0) = \frac{1}{2} \|P_i - A_i^0\|_1$ 。因为补集差为零，可靠部分差为 $\beta m_i (q_i^* - a_i^0)$ ，

$$TV(P_i, A_i^0) = \beta m_i TV(q_i^*, a_i^0) \leq \beta m_i,$$

最后一步使用任意两个概率分布的 L1 距离不超过 2。原模型给可靠 keys 的质量越小，本教师能改变的总质量也越小。

3.9 稳定计算和一个完整手算例子

设原始可靠 logits 的指数和为 D_K ，完整 logits 的指数和为 D 。由 $A_{ij}^0 = e^{S_{ij}/D}$ 和 $m_i = D_K/D$ ，条件分布为 $a_{ij}^0 = e^{S_{ij}/D_K}$ 。代入 P5， D_K 再次抵消，因此

$$q_i^* = \text{softmax}_{j \in K_{\text{rel}}} (S_{ij}^0 - c_{ij}).$$

实现用这一式直接计算 q_i^* ，从完整 softmax 取得 m_i ，不必对可能下溢的 a_i^0 取 log。教师概率与 log-softmax 使用 FP32。

取一个透明 query，原关系为 $A_i^0 = (0.1, 0.2, 0.3, 0.4)$ ，仅第 2、3 个 keys 可靠，代价为 $(0, \log 2)$ ， $\beta=0.5$ 。

1. 可靠总质量 $m_i = 0.2 + 0.3 = 0.5$ 。
2. 原条件概率 $a_i^0 = (0.4, 0.6)$ 。
3. 兼容系数为 $(1, 1/2)$ ，未归一化权重为 $(0.4, 0.3)$ 。
4. 归一化常数 $Z_i^{\text{norm}} = 0.7$ ，故 $q_i^* = (4/7, 3/7)$ 。
5. 乘回质量并补齐， $G_i = (0.1, 2/7, 3/14, 0.4)$ 。
6. 混合后 $P_i = (0.1, 17/70, 9/35, 0.4)$ ，约为 $(0.1, 0.242857, 0.257143, 0.4)$ 。
7. 中间两项总和仍为 0.5；两侧概率保持；行和仍为 1。

还可得到精确目标 logits 的解释。令可靠位置的偏移

$$d_{ij} = \log (1 - \beta + \beta e^{-c_{ij}} / Z_i^{\text{norm}}),$$

补集偏移为零。则 $\exp(S_{ij}^0 + d_{ij}) = D \cdot P_{ij}$ ，对所有 keys 求和得到 $D \sum P_{ij} = D$ ，故 $\text{softmax}(S_i^0 + d_i) = P_i$ 。一般不能把最终 P 简化为完整 $\text{softmax}(S_i^0 - \beta c_i)$ ；后者既不等价于概率混合，也不自动保持可靠总质量。

4. 为什么关系损失必须包含全部 keys [P9]

仍固定一行，令学生关系为 A_i^s 。教师在可靠集合上的质量是 m ，学生对应质量为 $n = \sum_{\{j \in K_{\text{rel}}\}} A_{ij}^s$ 。暂取 $0 < m, n < 1$ 。

定义教师和学生的可靠条件分布分别为 p_K 、 a_K^s ，补集条件分布分别为 a_{-K}^0 、 a_{-K}^s 。教师补集等于原关系，所以补集条件分布带上标 0。

对于可靠 key：

$$P_j = mp_{K,j}, \quad A_j^s = na_{K,j}^s.$$

将其代入这一部分的 KL，逐步拆 log：

$$\begin{aligned} \sum_{j \in K_{rel}} P_j \log \frac{P_j}{A_j^s} &= \sum_j mp_{K,j} \log \frac{mp_{K,j}}{na_{K,j}^s} \\ &= m \sum_j p_{K,j} \left(\log \frac{m}{n} + \log \frac{p_{K,j}}{a_{K,j}^s} \right) \\ &= m \log \frac{m}{n} + m D_{KL}(p_K \| a_K^s). \end{aligned}$$

最后一步使用 $\sum p_{K,j}=1$ 。补集同理，把 m 、 n 换成 $1-m$ 、 $1-n$ ，得到

$$\begin{aligned} D_{KL}(P \| A^s) &= m \log \frac{m}{n} + (1-m) \log \frac{1-m}{1-n} \\ &\quad + m D_{KL}(p_K \| a_K^s) + (1-m) D_{KL}(a_{-K}^0 \| a_{-K}^s). \end{aligned} \tag{P9}$$

第一行是可靠／不可靠二分事件之间的 Bernoulli KL，约束总质量；第二行约束两个集合内部的具体分布。 $m=0$ 或 1 等情况按极限处理，不对零质量条件分布强行做除法。

只对可靠 keys 归一化并蒸馏，可能出现这样的学生：可靠部分内部比例完全正确，但把可靠总质量从 0.5 降到 0.01 。条件 KL 看不出错误，完整 KL 会惩罚它。

因此原计划允许**抽 query 行**，但不能裁剪 keys 改变 softmax 分母。背景 queries 以 A^0 为教师；混合、无效和全局 queries 不参加关系项，但仍参加正常前向。

5. 为什么必须先做 oracle：关系目标不自动等于有用关系

5.1 固定读出，才能解释关系干预〔D1〕

令 E_0 表示冻结骨干， D_ψ 表示已经完成公共预热的深度读出， ψ_0 是其固定参数，基线函数为 $f_0 = D_\psi \circ E_0$ 。先确认读出能够拟合深度并具有合理开发误差，再拿它作诊断。

把候选配置记为 $c=(l,h,\beta)$ ，分别表示 block、head 和教师混合强度。这里 c 是候选编号，不是 P1 的带双下标代价 c_{ij} 。在选定头执行 $A^0 V A^0 \rightarrow P V A^0$ ，重算完整后续网络和同一个固定读出，得到 f_c^{oracle} 。

这个比较只改变关系矩阵；若每个候选都重新训练读出，则观测差异同时含有重新训练的变化，不再是此处的固定变量诊断。

为定义收益，取独立场景组 g ，令 $\Omega_T(I)$ 表示图像 I 中合法透明像素集合， g_T 表示 g 中该集合非空的图像。先对像素求 MAE，再对图像平均：

$$e_g(f) = \frac{1}{|g_T|} \sum_{I \in g_T} \frac{1}{|\Omega_T(I)|} \sum_{p \in \Omega_T(I)} |f(I)_p - Z_p^*|, \quad \Delta_g(c) = e_g(f_0) - e_g(f_c^{\text{oracle}}). \tag{D1}$$

这里 Z_p^* 是像素级 GT。先做内层平均，使透明区域较大的图像不自动拥有更高权重；再做组内平均，随后按组宏平均，避免一个包含大量近邻视角的场景主导结论。基线误差减去干预误差，所以正 Δ 表示改善。没有合法透明图像的组不进入透明平均，但仍应保留背景评估记录。

5.2 层、头和 β 的选择是验证流程，不是理论最优解

保留计划的有限搜索：H 的 0-based 候选 blocks 为 [15,23,31]，B 为 [5,8,11]；每层固定种子预抽 8 个不同 heads，分别形成 24 个层/头候选。 $\beta \in \{0, 0.25, 0.5\}$ ，每个骨干有 48 个正 β 候选， $\beta=0$ 为身份检查。

先在 D_select 上筛选满足背景和边界约束的候选，再在独立 D_confirm 上只检验锁定方案。不能看完确认结果后继续改头，却仍把该数据称为未使用的确认集。 β 、可靠性阈值和关系位置都不能借助真实测试标签选择。

背景及边界容忍量以毫米固定在选择前。按计划，以独立组做 2,000 次配对 bootstrap，报告平均收益、单侧 95% 下界和失败组比例；它表达有限数据下的证据，不给出总体绝对保证。

5.3 为什么两个好头相加不一定更好 (D2)

设单头 h_1 、 h_2 的平均收益分别为 $\Delta_{\{h_1\}}$ 、 $\Delta_{\{h_2\}}$ ，同时干预的收益为 $\Delta_{\{h_1, h_2\}}$ 。定义交互项

$$\mathcal{I} = \Delta_{\{h_1, h_2\}} - \Delta_{\{h_1\}} - \Delta_{\{h_2\}}. \quad (D2)$$

从“总收益=单头收益之和+额外相互作用”移项即得该式。网络中的非线性、两个头内容重叠以及下游敏感性，都可能使交互项为负。即便 attention 子层中两头的特征增量可相加，MAE 的变化也不线性可加。因此默认只适配一个 head；两个 heads 必须重新检验联合效果。

5.4 oracle 能说明的范围

Oracle 为每张图读取 GT 来构造 P，属于特权诊断；它不是 RGB-only 部署结果。它也不是学生性能的严格上界：学生会训练 Q/K 和读出，而 oracle 的读出固定。

完整证据链有四个不同问题：

1. 干预关系是否有用？
2. 单 RGB 学生能否学会其中可预测的部分？
3. 是否超过同容量、同训练预算的普通 LoRA？
4. 是否在封存真实域成立？

任何一项都不能直接推出后一项。

6. Q/K LoRA：怎样把关系目标变成可部署参数

6.1 从低秩矩阵乘积得到学生投影 (M1-M2)

选定一个 block 中 k 个 heads，它们的合计输出宽度为 kd 。引入秩参数 r ，输入因子 U_Q 、 U_K 的大小均为 $C \times r$ ，输出因子 B_Q 、 B_K 的大小均为 $r \times kd$ ； η 为固定缩放系数，起点为 1。

以两个小矩阵的乘积定义投影增量：

$$\Delta W_Q = \eta U_Q B_Q, \quad \Delta W_K = \eta U_K B_K, \quad U_{Q/K} \in \mathbb{R}^{C \times r}, B_{Q/K} \in \mathbb{R}^{r \times kd}. \quad (M1)$$

矩阵 U_{QB_Q} 的每一列都是 U_Q 的 r 列的线性组合，因此其列空间维数不超过 r ，即 $\text{rank}(\Delta W_Q) \leq r$ ； K 同理。这是 LoRA 的低秩保证。 [LoRA 原论文](#)

把总投影写成 $W^0 + \Delta W$ ；下面这个中间展开暂省略 sel ， Q 、 W_Q^0 和 b_Q^0 均指选中 heads 拼接后的子矩阵。利用矩阵乘法分配律：

$$X(W_Q^0 + \eta U_Q B_Q) + b_Q^0 = XW_Q^0 + b_Q^0 + \eta(XU_Q)B_Q.$$

对应学生的选中输出：

$$Q_{sel}^s = XW_{Q,sel}^0 + b_{Q,sel}^0 + \eta(XU_Q)B_Q, \quad K_{sel}^s = XW_{K,sel}^0 + b_{K,sel}^0 + \eta(XU_K)B_K. \quad (M2)$$

上标 s 表示学生；先算 XU 的 $N \times r$ 低维表示，再乘 B 恢复 $N \times kd$ 增量，将其散射到选中 heads 的对应输出位置。所有 V 、未选 Q/K 通道及其他原骨干参数冻结。

在同一种投影内，选中 heads 共享 U ； Q 与 K 的 U 不共享。如果改成每个 head 独立一套 U ，就改变了参数量与容量。若代码采用 $\eta = \alpha_{\text{LoRA}}/r$ ，必须显式记录 α_{LoRA} ，不能把更换秩同时引起的缩放变化藏起来。

6.2 参数数量如何得到 (M3)

一个 Q 增量需要 Cr 个 U 参数、 rkd 个 B 参数，总计 $r(C+kd)$ 。 K 再需要同样数量，所以

$$P_{FAR} = 2r(C + kd). \quad (M3)$$

$H/16+$ 取 $C=1280$ 、 $d=64$ 、 $r=4$ 、 $k=1$ ：

$$P_{FAR} = 2 \times 4 \times (1280 + 64) = 8 \times 1344 = 10752.$$

$k=2$ 时为 $2 \times 4 \times (1280+128)=11264$ ； $r=8$ 、 $k=1$ 时为 21504。 $B/16$ 的 $C=768$ 、 $d=64$ ，因此 $r=4$ 的单头和双头分别为 6656、7168。

这个计数只包含 Q/K LoRA，不包含投影重组、解码器或 C 的两个分支。每头独立 U 的变体则为 $2kr(C+d)$ ，不能沿用上表。

6.3 为什么单层设置能保留当前 V (M4-M5)

只有一个适配层、它之前的骨干完全冻结，并且同一 RGB 的前向确定时，学生和原模型在该层的输入相同：

$$H^s = H^0, \quad X^s = X^0, \quad V^s = X^s W_V^0 + b_V^0 = V^0.$$

注意：这是**选中层**的相等关系，不是全网络每层都相等。

将学生与原模型 $A4$ 的第一个式子相减，相同的输入残差、输出偏置和未改 heads 全部抵消：

$$U^s - U^0 = \left[\sum_{h \in H_{sel}} (A_h^s - A_h^0) V_h^0 W_{O,h} \right] \Gamma_1. \quad (M4)$$

H_{sel} 表示选中 heads 的集合，其大小为 k 。该式不是一阶近似；在上述条件下，它是 attention 子层的精确差。

但整个 block 还包含前馈残差。两条路径的 U 已不同，继续相减：

$$H_{next}^s - H_{next}^0 = (U^s - U^0) + [MLP(LN_2(U^s)) - MLP(LN_2(U^0))]\Gamma_2. \quad (M5)$$

因此后续层的输入、Q/K/V 和所有 token 表示都可能改变。原目标保持了某些概率，不能推出最终背景特征完全不变。

同一输入 X 也允许用原始 Q/K 重算固定 A^0 ，不必另放一个完整教师骨干。若未来适配多个层，后面的 X 已随前面 LoRA 改变，必须重新建立真正的原模型路径；不能继续把学生 X 上的原投影称为固定原教师。

6.4 零增量初始化与合并部署〔M6〕

初始化 U 为小随机值、 $B=0$ ，则 $\Delta W = \eta U B = 0$ 。所有读出参数相同且计算模式一致时，学生初始函数等于公共基线，便于 H1/H2 严格配对。

训练后把更新写入原权重对应位置：

$$W_{Q/K}^{deploy} = W_{Q/K}^0 + \text{Scatter}(\eta U_{Q/K} B_{Q/K}). \quad (M6)$$

Scatter 仅把选中输出列放回完整 Q 或 K 投影，其他列补零。由于线性分配律，合并后 XW^{deploy} 等于训练时的 $XW^0 + \eta(XU)B$ ，在实数算术下完全等价；不同精度下仍需实际量化误差。

PyTorch Linear 使用 [out,in] 权重，因此写入的是 $(\eta UB)^T$ 。packed QKV 中，第 h 个 head 的 Q 行为 $[hd, (h+1)d)$ ，K 行整体加 C，V 行整体加 2C；h 从 0 开始。

合并仅消去 FAR 的额外 LoRA 支路。教师、GT 深度、GT mask 和关系损失都不属于推理输入。若选架构 C，它自身的语义特征分支仍保留，不能把这部分计算也说成合并后消失。

7. 训练目标：正值米制深度、区域平衡和关系蒸馏

7.1 正值输出是参数化，不是绝对尺度证明〔L1〕

令深度头在像素 p 输出无量纲实数 u_p 。softplus 定义为 $\log(1+e^u)$ ，始终为正。引入参考单位 $z_{ref}=1m$ 和无量纲稳定项 $\epsilon_z=10^{-6}$ ：

$$\widehat{Z}_p = z_{ref}[\text{softplus}(u_p) + \epsilon_z]. \quad (L1)$$

括号内是正的无量纲数，乘 z_{ref} 才成为有物理单位的深度。用 ϵ_z 避免极小输出导致后续 log 不稳定。

若以典型训练深度 z_{typ} 初始化末层偏置，先令 $t=z_{typ}/z_{ref}-\epsilon_z>0$ ，再解 $\text{softplus}(b)=t$ ：

$$\log(1 + e^b) = t \Rightarrow e^b = e^t - 1 \Rightarrow b = \log(e^t - 1).$$

这个补充式仅说明如何实现原计划的典型深度初始化，不使用测试统计。

7.2 log-Huber 每一段如何构造〔L2〕

定义预测相对 GT 的对数误差

$$e_p = \log(\widehat{Z}_p / Z_p^*).$$

预测等于 GT 时 $e_p=0$ ；预测乘两倍时 $e_p=\log 2$ ；预测缩小两倍时为 $-\log 2$ 。这里分子分母同单位。

为了小误差区域平滑、大误差区域降低异常值影响，选择 Huber：

$$\rho_{\delta}(e) = \begin{cases} e^2/2, & |e| \leq \delta, \\ \delta(|e| - \delta/2), & |e| > \delta. \end{cases} \quad (L2)$$

$\delta > 0$ 为转折阈值，计划起点 $\delta = 0.1$ 。外侧为什么有 $-\delta^2/2$ ？

1. 正侧 $e > \delta$ 的线性段要求斜率等于内侧在 δ 处的导数 δ ，因此形如 $\delta e + b$ 。
2. 在 $e = \delta$ 连续，要求 $\delta^2 + b = \delta^2/2$ ，所以 $b = -\delta^2/2$ 。
3. 负侧用 $|e|$ 对称延拓，得到统一外侧 $\delta|e| - \delta^2/2$ 。

这也保证一阶导在两个接点连续。

7.3 把 AvgBal 展开成明确的像素权重〔L3〕

对一张图像， Ω_T 、 Ω_B 分别表示合法透明和非透明深度像素。仅收集非空集合形成集合族 C_{img} ，令 $n_{grp} = |C_{img}|$ 为非空类别数。

当 $n_{grp} > 0$ 时，计划的区域平衡平均严格等于

$$\mathcal{L}_{depth}^{img} = \frac{1}{n_{grp}} \sum_{\Omega \in C_{img}} \frac{1}{|\Omega|} \sum_{p \in \Omega} \rho_{\delta}(e_p).$$

于是 p 属于某个 Ω 时，其权重为 $w_p = 1/(n_{grp}|\Omega|)$ 。先平均每个类别，再平均现存类别；只有透明或只有背景时，该类权重为 1，而不是仍除以 2。

对训练 batch 中图像再等权平均，简记为

$$\mathcal{L}_{depth} = \text{AvgBal}_{p \in \Omega_T, \Omega_B} \rho_{\delta}(e_p). \quad (L3)$$

没有合法深度像素的样本不能制造一个 0/0：训练数据应优先筛出并记录；若保留，需在配置中明确其深度贡献为零及 batch 分母规则。此情况原计划尚未给出唯一的实现约定，本文不冒充已经锁定。

区域平衡有意增大透明区域的相对权重，目标不同于全图像素均匀风险。模型整体预测为 aZ^* 时， $e_p = \log a$ ； $a \neq 1$ 时 Huber 严格为正。因此本式没有进行每图尺度消除。 $a=2$ 、 $\delta=0.1$ 时，损失为 $0.1(\log 2 - 0.05) \approx 0.0643147$ 。

7.4 关系损失及其正确归约〔L4〕

令 ϕ 表示全部 FAR 因子参数， ψ 表示读出参数。训练目标把关系误差作为附加项：

$$\mathcal{L}_{rel} = \frac{1}{k} \sum_{h \in H_{sel}} \text{AvgBal}_{i \in T, B} D_{KL}(\text{sg}[P_{h,i}] \| A_{h,i}^s), \quad \mathcal{L} = \mathcal{L}_{depth} + \lambda_{rel} \mathcal{L}_{rel}. \quad (L4)$$

sg 表示停止梯度； $\lambda_{rel} \geq 0$ 为关系项权重。这里的 AvgBal 同样先按本图非空 query 类别平均，再对图像平均；整个样本无合法关系 query 时，关系项取零，合法深度项仍计算。

一行 KL 的具体计算是

$$\ell_{h,i} = \sum_{j=1}^N P_{h,ij} (\log P_{h,ij} - \log A_{h,ij}^s).$$

先对全部 keys 求和，再对 query、head、图像求平均。如果对 key 又除 N ，关系项会额外缩小 N 倍， $N=773$ 时不是可忽略的差别。通用库的 mean 或 batchmean 必须按实际张量轴核对。

主计划关系系数的开发候选为 {0,0.01,0.1,1}。λ_{rel}=0 就是同位置同参数的普通 LoRA，而不是去掉 LoRA 本身。教师 P 来自原 Q/K 和同步增强后的 GT，不能用 A^s.detach() 充当 A⁰。

7.5 为什么抽 query 可以保持无偏 [L5]

某类共有 n 个合法 query，均匀不放回抽 M=min(n,128) 个，令 ℓ_i 是第 i 行完整 key KL。用指示变量 ξ_i 表示是否抽中该行。

第一步，抽样均值可写为 M⁻¹ ∑_i ξ_i ℓ_i。第二步，均匀无放回抽样的每行入样概率均为 M/n。第三步，用期望的线性性：

$$\mathbb{E} \left[\frac{1}{M} \sum_{i \in \text{sample}} \ell_i \right] = \frac{1}{M} \sum_{i=1}^n \mathbb{E}[\xi_i] \ell_i = \frac{1}{M} \sum_{i=1}^n \frac{M}{n} \ell_i = \frac{1}{n} \sum_{i=1}^n \ell_i. \quad (\text{L5})$$

这里先固定图像和所有行损失，再对抽样随机性取期望。它只保证组内均值无偏；按类平衡后仍是计划规定的平衡风险，不变成像素均匀风险。若按误差优先抽样，就必须加入相应的重要性权重，或承认优化目标已变。

8. 从最终输出到 Q/K LoRA：完整反向传播

8.1 先推 KL 对单行 logits 的梯度 [L6]

固定教师概率 p_j，学生概率 a_j=exp(s_j)/∑_u exp(s_u)。此处 s_j 是该行第 j 个 logit，不是特征尺度编号。

先对 log-softmax 展开：

$$\log a_j = s_j - \log \sum_u e^{s_u}.$$

对 s_t 求导：第一项给出 Kronecker 指示 1[j=t]，第二项使用 log 的链式法则：

$$\frac{\partial}{\partial s_t} \log \sum_u e^{s_u} = \frac{e^{s_t}}{\sum_u e^{s_u}} = a_t.$$

所以

$$\frac{\partial \log a_j}{\partial s_t} = 1[j=t] - a_t.$$

KL 的第一项 ∑ p_j log p_j 与学生无关，其导数为零；对交叉熵部分求导：

$$\begin{aligned} \frac{\partial D_{KL}(p||a)}{\partial s_t} &= - \sum_j p_j (1[j=t] - a_t) \\ &= -p_t + a_t \sum_j p_j = a_t - p_t. \end{aligned} \quad (\text{L6})$$

最后一步必须使用教师行和为 1。行梯度求和为 ∑ a - ∑ p=0，对应 softmax 对行常数不变。

该式只属于**固定教师 KL**；深度损失的 logits 梯度不等于 a-p，下一节会单独展开。教师优化中的 KL(q||a⁰) 和学生训练中的 KL(P||A^s) 也不能交换方向。

8.2 深度末端的导数 [L9]

softplus(u)=log(1+e^u)。先求导：

$$\frac{d \text{softplus}(u)}{du} = \frac{e^u}{1 + e^u} = \frac{1}{1 + e^{-u}} = \sigma(u).$$

由 L1 以及 $e_p = \log(\hat{Z}_p/z_{\text{ref}}) - \log(Z_p^*/z_{\text{ref}})$ ，其中 z_{ref} 与 GT 均为常数：

$$\frac{\partial \hat{Z}_p}{\partial u_p} = z_{\text{ref}} \sigma(u_p), \quad \frac{\partial e_p}{\partial u_p} = \frac{1}{\hat{Z}_p} z_{\text{ref}} \sigma(u_p) = \frac{\sigma(u_p)}{\text{softplus}(u_p) + \epsilon_z}. \quad (\text{L9})$$

参考单位 z_{ref} 在比例中抵消，不意味着目标消除了尺度。Huber 导数逐段为

$$\rho'_\delta(e) = \begin{cases} e, & |e| \leq \delta, \\ \delta \text{sign}(e), & |e| > \delta. \end{cases}$$

先乘第 7.3 节的像素平衡权重 w_p ，得到单图梯度

$$\frac{\partial \mathcal{L}_{\text{depth}}^{\text{img}}}{\partial u_p} = w_p \rho'_\delta(e_p) \frac{\sigma(u_p)}{\text{softplus}(u_p) + \epsilon_z}.$$

这明确给出“误差惩罚 → log-depth → 正值输出”的所有因子。若 batch 含 B_{batch} 张参与该平均的图像，batch 目标对本图输出的梯度还需乘 $1/B_{\text{batch}}$ 。

8.3 冻结下游仍然需要输入梯度

把选中 attention 输出 O_h 之后的全部运算合并记为函数 T_ψ ，包括多头输出投影、当前 block 剩余部分、冻结 suffix、多层特征提取与读出。最终原始深度输出向量 $u = T_\psi(O_h, \text{其他输入})$ 。

用 $J_{[u, O_h]}$ 表示该函数对 O_h 的 Jacobian，即每个输出对每个输入元素的偏数组成的矩阵。将张量展平成向量后，链式法则是

$$\text{vec}(G_{O_h}^{\text{depth}}) = J_{u, O_h}^\top \nabla_u \mathcal{L}_{\text{depth}}.$$

G_O 表示“损失对 O 的同形状梯度”。这个式子不是把中间梯度省成神秘常数：Jacobian 按实际算子顺序相乘；有多层读出和残差支路时，各路径贡献相加。

例如冻结线性映射 $y = xW^0$ ，其微分 $dy = dxW^0$ ，所以输入梯度 $G_x = G_y(W^0)^\top$ 。冻结 W^0 仅表示不更新它，不表示 $G_x = 0$ 。若用 no_grad 包住 suffix，相当于直接截断这条链，深度项就不能训练上游 LoRA。

8.4 从 AV 汇聚回到 softmax

对选中 head，有 $O = AV$ 。选中层 V 对 ϕ 固定，微分为 $dO = (dA)V$ 。对标量损失使用内积：

$$d\mathcal{L} = \langle G_O, dO \rangle = \langle G_O, (dA)V \rangle = \langle G_O V^\top, dA \rangle.$$

这里 $\langle B, C \rangle = \sum_{ij} B_{ij} C_{ij}$ 为 Frobenius 内积，最后一个等号可逐元素展开验证。因此

$$G_A^{\text{depth}} = G_O^{\text{depth}} V^\top.$$

一般情况下也有 $G_V = A^\top G_O$ ，但在当前选中层，它不通向 Q/K LoRA 参数，因为 V 与 ϕ 无依赖。

接着对 softmax 本身求导。由商法则，或由第 8.1 节 log-softmax 导数乘 a_j ：

$$\frac{\partial a_j}{\partial s_t} = a_j(1[j = t] - a_t).$$

令 $g_j = \partial \mathcal{L}_{\text{depth}} / \partial a_j$ ，则

$$\begin{aligned}\frac{\partial \mathcal{L}_{\text{depth}}}{\partial s_t} &= \sum_j g_j a_j (1[j = t] - a_t) \\ &= g_t a_t - a_t \sum_j g_j a_j \\ &= a_t \left(g_t - \sum_j a_j g_j \right).\end{aligned}$$

这就是深度项的 logits 梯度。加上关系项，固定某行的关系平均权重 ω_i 后：

$$G_{S,i}^{\text{total}} = G_{S,i}^{\text{depth}} + \lambda_{\text{rel}} \omega_i (A_i^s - P_i).$$

未抽中的关系 query 令该项 $\omega_i=0$ ，但深度项仍然存在。C 若有分割辅助，令 λ_{seg} 表示分割项系数，还应加上 $\lambda_{\text{seg}} \cdot \partial \mathcal{L}_{\text{seg}} / \partial S$ ；这里是分割损失经完整网络回传到**当前 attention logits S**的梯度，不是 SegTail 输出处的像素 logits 梯度。

8.5 从打分到旋转后的 Q/K [L7]

完整打分矩阵 $S = \tilde{Q} \tilde{K}^\top / \sqrt{d}$ 。对两个矩阵都做微分：

$$dS = \frac{(d\tilde{Q}) \tilde{K}^\top + \tilde{Q} (d\tilde{K})^\top}{\sqrt{d}}.$$

代入 $dL = (G_S, dS)$ ，先看 Q 部分：

$$\langle G_S, (d\tilde{Q}) \tilde{K}^\top \rangle = \langle G_S \tilde{K}, d\tilde{Q} \rangle.$$

K 部分类似地重排求和索引，得到

$$G_{\tilde{Q}} = G_S \tilde{K} / \sqrt{d}, \quad G_{\tilde{K}} = G_S^\top \tilde{Q} / \sqrt{d}, \quad G_{q_i} = G_{\tilde{q}_i} R_i^\top. \quad (\text{L7})$$

最后一个式子来自 $\tilde{q}_i = q_i R_i$ ：其微分 $d\tilde{q}_i = (dq_i) R_i$ ，故梯度乘 $R_i^\top$ 。同理 $G_{k_i} = G_{\tilde{k}_i} R_i^\top$ 。这里旋转被视为固定的、相同位置编码，不对坐标参数求梯度。

逐元素看 K 梯度：

$$G_{\tilde{k}_j} = \frac{1}{\sqrt{d}} \sum_i G_{S,ij} \tilde{q}_i.$$

即便仅少量 query 的关系损失非零，它们也可能对**所有 keys**产生梯度。再加上 Q/K 权重跨 token 共享，不能把 FAR 说成只修改 mask 内像素。

8.6 从 Q/K 到 LoRA 两个因子 [L8]

先只推 Q，K 完全同理。本小节省略 sel，Q、 W_Q^0 、 b_Q^0 均指选中 heads 的拼接输出及对应投影。令 $W_{\text{eff}} = W_Q^0 + \eta U_Q B_Q$ ， $Q = X W_{\text{eff}} + b_Q^0$ ，且 X 对当前 ϕ 固定。

由 $dQ = X dW_{\text{eff}}$ ：

$$d\mathcal{L} = \langle G_Q, X dW_{\text{eff}} \rangle = \langle X^\top G_Q, dW_{\text{eff}} \rangle.$$

因此定义 $G_W = X^\top G_Q$ 。再对乘积 $\eta U B$ 求微分：

$$dW_{eff} = \eta[(dU)B + U(dB)].$$

分别代入内积并重排：

$$\begin{aligned} d\mathcal{L} &= \eta \langle G_W, (dU)B \rangle + \eta \langle G_W, U(dB) \rangle \\ &= \langle \eta G_W B^\top, dU \rangle + \langle \eta U^\top G_W, dB \rangle. \end{aligned}$$

直接读取各微分前的系数：

$$\nabla_U \mathcal{L} = \eta G_W B^\top, \quad \nabla_B \mathcal{L} = \eta U^\top G_W. \quad (\text{L8})$$

检查维度：G_W 为 C×kd，乘 B[⊤] 得 C×r，与 U 一致；U[⊤]G_W 为 r×kd，与 B 一致。

初始化 B=0 时，∇_U=0，但随机非零 U 通常使 ∇_B≠0；第一步更新 B 后，U 也能获得梯度。若 U、B 同时为零，两组梯度都为零，该支路无法从普通梯度下降启动。“随机 U 通常可更新”不是对任意损失和样本都保证非零。

8.7 把整个训练链连起来

深度路径：

$$\mathcal{L}_{depth} \rightarrow \hat{Z} \rightarrow u \rightarrow \text{读出与冻结 suffix} \rightarrow O = AV \rightarrow A = \text{softmax}(S) \rightarrow (\tilde{Q}, \tilde{K}) \rightarrow (Q, K) \rightarrow (U_Q, B_Q, U_K, B_K).$$

关系路径从 KL 直接进入 S，再共享同一后半段。训练总梯度就是各损失贡献相加；关系教师 P 全程停止梯度。

本文新增的数值检查用固定小型下游验证上述全链，再对 Q/K 以及四个 LoRA 因子做有限差分。它验证这条代数链，不代表已经完成真实 DINOv3 集成。

8.8 Jacobian 不是省略证明：基础算子的反传展开

本节补全上文“经过归一化、前馈和残差”的具体数学含义。下面把单个 token 或卷积位置写成列向量，只用于方便表达 Jacobian；Q/K 的矩阵行向量约定不变。

LayerNorm。 令 h 有 C 个通道，1 为全 1 向量， $\Pi_C = I - 11^\top / C$ 表示减均值算子。置 $t = \Pi_C h$ 、 $v = t^\top t / C$ 、 $s = \sqrt{(v + \epsilon_{LN})}$ ，归一化结果 $n = t/s$ 。

逐步微分：

$$dt = \Pi_C dh, \quad dv = \frac{2}{C} t^\top dt = \frac{2}{C} t^\top dh, \quad ds = \frac{dv}{2s} = \frac{t^\top dh}{Cs}.$$

第二个等号用 t 的通道和为零，所以 $t^\top \Pi_C = t^\top$ 。继续对 $n = t/s$ 使用商法则：

$$dn = \frac{dt}{s} - \frac{t ds}{s^2} = \left(\frac{\Pi_C}{s} - \frac{t t^\top}{C s^3} \right) dh.$$

最后输出 $x = \text{diag}(\gamma) n + b^{\wedge} \text{LN}$ ，故

$$J_{x,h} = \text{diag}(\gamma) \left(\frac{\Pi_C}{s} - \frac{t t^\top}{C s^3} \right).$$

输入梯度为 $J_{\{x,h\}}^\top g_x$ 。参数冻结时这项依然存在； $\epsilon_{LN} > 0$ 避免 $s=0$ 。

SwiGLU。将前馈写成 $a=W_1x+b_1$ 、 $b=W_2x+b_2$ 、 $t=\text{SiLU}(a)\odot b$ 、 $y=W_3t+b_3$ 。这里 W 按列向量式使用对应转置，不改变实际网络。

先对 sigmoid 求导： $\sigma(a)=1/(1+e^{(-a)})$ ，因此 $\sigma'(a)=\sigma(a)(1-\sigma(a))$ 。对 $\text{SiLU}(a)=a\sigma(a)$ 使用乘积法则：

$$\text{SiLU}'(a) = \sigma(a) + a\sigma(a)(1 - \sigma(a)).$$

由 y 传入梯度 g_y ，则依次有

$$g_t = W_3^\top g_y, \quad g_a = g_t \odot b \odot \text{SiLU}'(a), \quad g_b = g_t \odot \text{SiLU}(a), \quad g_x = W_1^\top g_a + W_2^\top g_b.$$

最后求和是因为 x 同时进入两条线性分支。

残差和 LayerScale。若 $y=x+f(x)$ ，则 $dy=dx+J_f dx=(I+J_f)dx$ ，故 $g_x=g_y+J_f^\top g_y$ 。若 $y=\Gamma x$ ，则 $dy=\Gamma dx$ 、 $g_x=\Gamma^\top g_y$ 。将这两条规则和上面的 LayerNorm、SwiGLU 组合，就得到 A4、M5 中冻结 block 的完整输入反传。

这些导数说明梯度通路存在，不保证梯度不会衰减、放大或因特殊样本而恰好为零。

9. 理论保证与表达能力边界

9.1 小 KL 如何控制当前子层输出差〔B1〕

固定一个 head 的一个 query，令教师、学生关系分别为 p 、 a 。把固定 value、输出投影和 LayerScale 合并为

$$v'_j = v_j W_{O,h} \Gamma_1, \quad M = \max_j \|v'_j\|_2.$$

先用三角不等式，再用 M 的定义：

$$\left\| \sum_j (a_j - p_j) v'_j \right\|_2 \leq \sum_j |a_j - p_j| \|v'_j\|_2 \leq M \sum_j |a_j - p_j| = M \|a - p\|_1.$$

下一步使用自然对数形式的 Pinsker：

$$\|a - p\|_1 \leq \sqrt{2D_{KL}(p\|a)}.$$

两式相接：

$$\left\| \sum_j (a_j - p_j) v'_j \right\|_2 \leq M \|a - p\|_1 \leq M \sqrt{2D_{KL}(p\|a)}. \quad (\text{B1})$$

为不把 Pinsker 当作未解释黑箱，可以如下证明其常数。

1. 令 $E=\{j:p_j \geq a_j\}$ ， $u=\sum_{j \in E} p_j$ 、 $v=\sum_{j \in E} a_j$ 。正负差的总和相抵，所以 $\text{TV}(p,a)=u-v=1/2\|p-a\|_1$ 。
2. 在 E 与补集分别分解 KL，如同 P9。两个条件 KL 非负，因此完整 KL 至少为二元 KL：

$$D_{KL}(p\|a) \geq f(u) := u \log \frac{u}{v} + (1-u) \log \frac{1-u}{1-v}.$$

3. 固定 $v \in (0,1)$ ，有 $f(v)=0$ 、 $f'(v)=0$ ，并且

$$f''(u) = \frac{1}{u} + \frac{1}{1-u} = \frac{1}{u(1-u)} \geq 4,$$

因为 $u(1-u) \leq 1/4$ 。

4. 从 v 积分到 $u \geq v$ 。先由 $f'(v)=0$ 得

$$f'(t) = \int_v^t f''(r) dr \geq \int_v^t 4 dr = 4(t-v).$$

再由 $f(v)=0$ 得

$$f(u) = \int_v^u f'(t) dt \geq \int_v^u 4(t-v) dt = 2(u-v)^2 = 2TV(p, a)^2 = \frac{1}{2} \|p - a\|_1^2.$$

结合第一步的完整 KL 下界，移项并开根得到所需不等式。边界以连续极限处理；若 KL 为无穷，上界平凡成立。

B1 控制的是固定 V 下的当前子层差，并不控制训练后读出与完整 suffix 的最终深度误差。若想延伸到最终输出，必须另有相应区域上的 Lipschitz 常数；原计划没有证明该常数，本文不虚构。

平均 KL 小也不表示每行都小：少数困难边界行可能保留较大 KL。因此还需实际误差图、边界指标和失败样例。

9.2 单 RGB 学生的理想目标是条件平均，而不是每个 GT 教师 [B2]

固定一个 head/query 坐标及 RGB 输入 x ，训练数据中可能仍有无法仅由 x 消除的几何不确定性。把该行教师分布记为随机向量 P ，将 GT query 选择、区域平衡等合并为非负权重 w 。

先忽略 LoRA 容量和深度项，只研究任意概率预测 $a(x)$ 的条件风险：

$$R_x(a) = \mathbb{E}[w D_{KL}(P \| a) \mid x].$$

展开 KL，将与 a 无关的部分记为 C_x ，定义 $\mu_j = \mathbb{E}[w P_j \mid x]$ ：

$$R_x(a) = C_x - \sum_j \mu_j \log a_j.$$

在 $\sum a_j = 1$ 下加入乘子 ν ，对 a_j 求导：

$$-\frac{\mu_j}{a_j} + \nu = 0 \Rightarrow a_j = \frac{\mu_j}{\nu}.$$

求和后 $\nu = \sum \mu_j = \mathbb{E}[w \sum P_j \mid x] = \mathbb{E}[w \mid x]$ ，所以

$$a^*(x) = \frac{\mathbb{E}[w P \mid x]}{\mathbb{E}[w \mid x]}, \quad \mathbb{E}[w \mid x] > 0. \quad (\text{B2})$$

若某一 $\mu_j = 0$ ，对应最优概率为零，可用边界极限理解。若 $\mathbb{E}[w \mid x] = 0$ ，则该条件下没有监督，风险不能确定 a 。

还有一个直接的最优性检验。令 $W_x = \mathbb{E}[w \mid x]$ ，利用 $\mu_j = W_x a_j^*$ ：

$$\begin{aligned} R_x(a) - R_x(a^*) &= \sum_j \mu_j \log \frac{a_j^*}{a_j} \\ &= W_x D_{KL}(a^* \| a) \geq 0. \end{aligned}$$

因此最优解由加权条件均值给出。只有 w 恒为同一正数，或权重与教师的条件关系满足相应条件时，才可简化为 $E[P|x]$ 。

实际学生还受固定特征、小秩投影、有限数据和深度损失约束，因此 B2 不是它的必达性能。它解释了为什么“GT oracle 有益”与“RGB 学生能完全复制 GT 教师”是不同命题。

9.3 无 RoPE 时，低秩打分增量如何得到〔B3〕

先看简化情形：固定 X ，不使用 RoPE。令原投影为 Q 、 K ，增量为 δQ 、 δK 。展开乘积并减去原始打分：

$$\begin{aligned}\Delta S &= \frac{(Q + \delta Q)(K + \delta K)^\top - QK^\top}{\sqrt{d}} \\ &= \frac{Q\delta K^\top + \delta QK^\top + \delta Q\delta K^\top}{\sqrt{d}} \\ &= \frac{\delta Q(K + \delta K)^\top + Q\delta K^\top}{\sqrt{d}}.\end{aligned}$$

设 Q/K 更新的秩上界分别为 r_Q 、 r_K 。由于 $\text{rank}(AB) \leq \min(\text{rank } A, \text{rank } B)$ ，且 $\text{rank}(A+B) \leq \text{rank } A + \text{rank } B$ ：

$$\text{rank}(\Delta S) \leq r_Q + r_K. \quad (\text{B3})$$

关键是把交叉项并入 $\delta Q(K+\delta K)^\top$ ，不能机械地把三项分别计为 $3r$ 。这里 B3 的矩阵表达式就是上面最后一行。

9.4 实际 RoPE 为什么破坏这个简单秩结论

RoPE 对不同 token 使用不同 R_i ，这不是整个矩阵右乘同一个 R 。

最小例子：两行原本都是 $(1,0)$ ，矩阵秩为 1；第一行旋转 0° ，第二行旋转 90° ，得到两条正交行，秩变成 2。每行旋转都保长度，但不保整个跨 token 矩阵的秩。

所以 $\text{rank}(\delta Q) \leq r$ 不保证 $\text{rank}(\delta \tilde{Q}) \leq r$ ，实际 $H/16+$ 不能直接套用 $\text{rank}(\Delta S) \leq 2r$ 。

安全的一般界来自：学生 $S^s = \tilde{Q}^s(\tilde{K}^s)^\top / \sqrt{d}$ 的秩不超过 d ，原始 S^0 同样不超过 d 。因此

$$\text{rank}(\Delta S) = \text{rank}(S^s - S^0) \leq \min(N, 2d).$$

新增数值检查给出 rank-1 投影增量经过逐 token 旋转后，打分增量秩达到 4、严格大于 $2r=2$ 的反例。这不是说实际训练一定达到该秩，而是反驳“所有情况下必定 $\leq 2r$ ”的断言。

softmax 还是非线性变换， $A^s - A^0$ 也不能被称为低秩概率更新。本文只对权重增量 $\Delta W = \eta UB$ 声明低秩。

9.5 即使不限制 LoRA，单头也不能表达任意教师〔B4〕

设一个单头输出严格正的 attention 矩阵 A ， S 为其 logits。逐行 log-softmax 给出

$$\log A = S - b\mathbf{1}^\top,$$

其中 $b_i = \log \sum_j \exp(S_{ij})$ ， $\mathbf{1}$ 是长度 N 的全 1 列向量。这里 $\log A$ 表示逐元素取对数。

定义右侧去行常数投影 $\Pi = I - \mathbf{1}\mathbf{1}^\top / N$ 。因为 $\mathbf{1}^\top \Pi = 0$ ，右乘得

$$(\log A)\Pi = S\Pi, \quad \text{rank}((\log A)\Pi) \leq d. \quad (\text{B4})$$

第二步利用 $\text{rank}(S) \leq d$ 及右乘不增加秩。右乘 Π 的作用是从每一行减掉该行均值，去除 softmax 无法识别的行常数自由度。

逐行 GT 重加权和混合生成的 P 未必满足该必要条件。即便满足，固定 X 、原投影附近的更新以及小秩因子仍可能无法实现它。因此“教师概率合法”“单头可表达”“小秩学生可拟合”“最终深度更好”必须分别判断。

10. 三种深度架构：从共同特征到最终预测

10.1 这里推导的是数据流与维度，而不是架构必然最优性

N1-N9 是原计划指定的结构。下面解释每个算子为何能连接、对应什么张量、梯度如何流动，不将人为选择的结构写成物理定律的唯一解。DPT 多层重组与融合、U-Net 收缩／扩张及跳连均有既有基础。[DPT 原文](#)、[U-Net 原文](#)

10.2 四层 token 如何变成四个真正的尺度〔N1〕

此节以 H_{img} 、 W_{img} 表示输入图像高宽，避免和第 2 节的 block 特征 H 混淆。

$H/16+$ 提取 0-based blocks $[7,15,23,31]$ ， $B/16$ 为 $[2,5,8,11]$ 。四个输出都先按同一冻结 backbone norm 处理，只取 patch tokens，再还原成 F_s ， $s=1,2,3,4$ 表示四个读取位置。

每个 F_s 原始形状相同，都是 $C \times (H_{img}/16) \times (W_{img}/16)$ 。不同 block 的层深不同，但空间网格并没有天然改变。

令 $c=128$ 表示本节共同读出通道宽度，令 R_s 表示可训练的尺度重组。定义

$$P_s = \mathcal{R}_s(F_s), \quad P_s \in \mathbb{R}^{c \times H_{img}/2^{s+1} \times W_{img}/2^{s+1}}, \quad s = 1, 2, 3, 4. \tag{N1}$$

这里带尺度下标的 P_s 是**特征图**，不是第 3 节的教师概率 P_i 。

逐步得到四个尺度：

- 1. 所有 F_s 先用 1×1 卷积，将每个空间位置的 C 个通道投影为 c 个通道。
- 2. $s=1$ ：原 $/16$ 网格双线性放大 4 倍，再用 3×3 卷积，得到 $/4$ 。
- 3. $s=2$ ：放大 2 倍并卷积，得到 $/8$ 。
- 4. $s=3$ ：保留 $/16$ 网格。
- 5. $s=4$ ：使用 stride-2、 3×3 卷积，得到 $/32$ ；padding 与对齐规则固定。

384×512 时对应如下：

特征	通道	高×宽	与输入的比例
P_1	128	96×128	$/4$
P_2	128	48×64	$/8$
P_3	128	24×32	$/16$

P ₄	128	12×16	/32
----------------	-----	-------	-----

若 stride-2 卷积使用 kernel=3、padding=1，输出高度为 floor((h+2-3)/2)+1；偶数 h 时等于 h/2。实际实现必须明确此类 padding 规则，而非只口头命名四尺度。

三架构使用同样的重组设计，各训练运行有独立权重。“共享设计”不表示不同实验之间共享训练过程。

10.3 卷积、GroupNorm、残差块和拼接块的明确含义

对输入特征 x，3×3 卷积输出第 o 个通道、位置 p 的计算是

$$y_{o,p} = b_o + \sum_{a=1}^{c_{in}} \sum_{\delta \in \{-1,0,1\}^2} W_{o,a,\delta} x_{a,p+\delta}.$$

δ 枚举 9 个空间偏移，a 枚举输入通道。故卷积权重数为 9c_{in} c_{out}，若启用 bias 再加 c_{out}。不同拼接和分支会增加容量，相同输出宽度并不等于相同参数。

原计划卷积模块采用 Conv→GroupNorm→GELU；GroupNorm 在每个样本中，把固定通道组及其空间位置一起计算均值和方差，归一化后再逐通道仿射。c=128 时可用 8 组，每组有 16 个通道，不依赖 batch 内其他图像。

其公式与第 2.2 节 LayerNorm 同型，只需把“C 个通道”换为“本组所有通道与空间元素”。因此第 8.8 节的微分推导可按每组元素数直接应用。GELU 是逐点非线性；若使用精确形式 GELU(x)=xΦ(x)，其中 Φ 是标准正态累积分布，则由乘积法则其导数为 Φ(x)+xφ(x)，φ 为对应密度。实现若用近似版本，须按实际算子计算而不混称精确版本。

定义 RB(x)=x+F₂(F₁(x))，F₁、F₂ 为同宽卷积模块；残差前后形状一致。CC([x,y]) 先沿通道拼接得到 2c 通道，再用两层卷积投回 c 通道。

拼接本身不混合数值，只重排索引；反传时梯度按通道拆回两路。逐元素相加的反传则把相同输出梯度分别传给两路。固定双线性上采样可写成 y=Tx，T 为插值权重矩阵，由 dL=(g_y,Tdx) 得 g_x=T^Tg_y。

共同深度 tail：从 /4 上采样至 /2，3×3 卷积 c→32、GELU、3×3 卷积 32→1，再上采样至 H_{img}×W_{img}，输出原始深度数值 u；Tail 本身不包含 PositiveDepth，其后单独应用 L1 一次。这里末端遵循计划单独规定的 tail，不额外插入一套归一化或分割门控。

10.4 架构 A：DPT 逐级残差融合〔N2-N3〕

令 Y_s 为尺度 s 的融合特征。先处理最粗尺度，再逐级上采样并与相应尺度特征相加：

$$Y_4 = RB_4(P_4), \quad Y_s = RB_s(RB'_s(P_s) + Up_{s+1 \rightarrow s}(Y_{s+1})), \quad s = 3, 2, 1. \tag{N2}$$

每个步骤的维度依据：

1. Y_{s+1} 有 c 通道，空间大小为 P_s 的一半。
2. Up 将高宽各放大两倍，成为与 P_s 同形状的张量。
3. RB'_s(P_s) 同样有 c 通道，所以可以逐元素相加。
4. RB_s 进一步融合，输出仍与 P_s 同形状。

得到 /4 的 Y_1 后：

$$\hat{Z}_A = \text{PositiveDepth}(\text{Tail}(Y_1)). \quad (\text{N3})$$

PositiveDepth 就是 L1。A 是计划主基线和六组实验的读出。/4 特征来自 /16 token 重组，并不意味着已经无损恢复原 RGB 的杯沿细节。

10.5 架构 B：在 ViT 后接完整 U 形读出〔N4–N6〕

令 E_s 表示 U 形路径的收缩侧特征。先处理 /4 特征，再逐级下采样，同时接入相应 P_s ：

$$E_1 = RB(P_1), \quad E_s = CC_s([P_s, \text{Down}(E_{s-1})]), \quad s = 2, 3, 4. \quad (\text{N4})$$

Down 使空间尺寸减半，与 P_s 对齐；拼接产生 $2c$ 通道，CC 压回 c 。Down 按计划固定为抗混叠策略或 stride 卷积的明确实现，不默认替换为 MaxPool。

令 U_s 表示扩张侧特征，此处 U_s 是特征图，不是 LoRA 的输入因子 U_Q/U_K 。从 E_4 开始：

$$U_4 = RB(E_4), \quad U_s = CC'_s([E_s, \text{Up}(U_{s+1})]), \quad s = 3, 2, 1. \quad (\text{N5})$$

每层把粗尺度上下文放大，与同尺度 E_s 的跳连特征拼接，再卷积融合。最终

$$\hat{Z}_B = \text{PositiveDepth}(\text{Tail}(U_1)). \quad (\text{N6})$$

B 仍以同一个 DINOv3 骨干提取特征，之后使用 U-Net 风格读出；末端不再运行 DPT。它是否更善于边界恢复，要由数据验证。

10.6 架构 C：双分支 U-Net 特征融合后接 DPT〔N7–N9〕

C 复用 N1，且只建立一套 N4 共享收缩路径 E_s 。两个独立扩张分支分别记为 G_s 、 S_s ，表示几何特征与透明语义特征。此处 S_s 是语义特征，不是 attention logits S_o 。

初始化最粗两支并向细尺度展开：

$$G_4 = RB_g(E_4), \quad S_4 = RB_m(E_4), \quad G_s = CC_s^g([E_s, \text{Up}(G_{s+1})]), \quad S_s = CC_s^m([E_s, \text{Up}(S_{s+1})]), \quad s = 3, 2, 1. \quad (\text{N7})$$

每支、每层仍为 c 通道。几何支暂时只输出供深度读出使用的特征，**不额外监督一个中间深度**。


语义支 /4 特征经 SegTail 恢复像素 logits，取 sigmoid 得到透明概率：

$$\hat{M} = \sigma(\text{SegTail}(S_1)). \quad (\text{N8})$$

每个尺度将 G_s 、 S_s 拼接为 $2c$ 通道，经过 1×1 卷积映射到 c ，再与原 P_s 残差相加：

$$\tilde{P}_s = P_s + \text{Conv}_{1 \times 1, s}([G_s, S_s]), \quad \hat{Z}_C = \text{PositiveDepth} \left(\text{Tail} \left(\text{DPTFuse}(\{\tilde{P}_s\}_1) \right) \right). \quad (\text{N9})$$

这一步先构建增强的四尺度特征，再复用 N2 的 DPT 融合，最后接共同 tail。输入已是四尺度，**不能再次执行 token reassembly**。



图中 A/B/C 是三种独立模型选项，不表示部署时同时运行三种读出。C 的预测 mask 源自 RGB；主 C 不使用硬 mask 门控，不将 mask=0 的深度设零。即使部署时不输出最终分割图，S_s 仍参加融合。语义与几何联合学习已有 MODEST 等先例，此处推导只说明本计划结构。[MODEST 原论文](#)

11. 双分支的分割目标与完整梯度

11.1 从 Bernoulli 似然得到 BCE [S1]

对有可靠分割标签的像素 p ，令 $m_p \in \{0,1\}$ 表示是否透明， a_p 表示 SegTail 的实数输出， $\hat{M}_p = \sigma(a_p)$ 表示透明概率。

一个 Bernoulli 模型给该标签的概率为

$$\Pr(m_p | I) = \hat{M}_p^{m_p} (1 - \hat{M}_p)^{1-m_p}.$$

当 $m_p=1$ 时留下 $\hat{M}_p$ ；当 $m_p=0$ 时留下 $1-\hat{M}_p$ 。取负对数，把乘积拆成和，就得到单像素 BCE：

$$\ell_p^{seg} = -m_p \log \hat{M}_p - (1 - m_p) \log(1 - \hat{M}_p).$$

对非空正类、负类分别平均，再等权平均：

$$\mathcal{L}_{seg} = \text{AvgBal}_{p:m_p=1, p:m_p=0} \left[-m_p \log \widehat{M}_p - (1 - m_p) \log(1 - \widehat{M}_p) \right]. \quad (\text{S1})$$

有效域以分割标签可靠性为准，不能把 padding 作为背景，也不必错误地要求所有可靠分割标签都有合法深度。区域权重规则与第 7.3 节相同，只是使用本项对应的有效标签集合。

11.2 BCE-with-logits 稳定形式和梯度

利用

$$\log \sigma(a) = a - \log(1 + e^a), \quad \log(1 - \sigma(a)) = -\log(1 + e^a),$$

代入 BCE：

$$\begin{aligned} \ell^{seg} &= -m[a - \log(1 + e^a)] - (1 - m)[- \log(1 + e^a)] \\ &= \log(1 + e^a) - ma = \text{softplus}(a) - ma. \end{aligned}$$

第一条恒等式由 $\sigma(a)=e^a/(1+e^a)$ 取 $\log$ 得到；第二条由 $1-\sigma(a)=1/(1+e^a)$ 得到。

因此导数为

$$\frac{\partial \ell^{seg}}{\partial a} = \sigma(a) - m = \widehat{M} - m.$$

再乘分割区域平衡权重和图像平均权重，就是实际 logits 梯度。稳定计算可用 $\max(a,0)+\log(1+\exp(-|a|)) - ma$ ； $a \geq 0$ 时提出 e^a ， $a < 0$ 时保持原式，即可验证它等于 $\text{softplus}(a)-ma$ 。

11.3 C 的总目标〔S2〕

引入非负系数 λ_{seg} ，原计划首轮候选为 $\{0,0.01,0.1\}$ ：

$$\mathcal{L}_C = \mathcal{L}_{depth} + \lambda_{rel} \mathcal{L}_{rel} + \lambda_{seg} \mathcal{L}_{seg}. \quad (\text{S2})$$

这是多任务加权和设计选择，没有理论保证三项天然同尺度。默认不加入 Dice、法线、边缘和中间深度损失；应观察各项数值及它们对 ϕ 的梯度范数，而不是仅按未加权 loss 大小判断作用。

11.4 逐尺度直接融合梯度〔S3〕

固定一个空间位置，将特征写成 c 维列向量。N9 的 1×1 卷积可按两支输入拆为 $W_{g,s}$ 、 $W_{m,s}$ ，均为 $c \times c$ 矩阵，另有偏置 b_s ：

$$\widetilde{P}_s = P_s + W_{g,s} G_s + W_{m,s} S_s + b_s.$$

令 $g_s = \partial \mathcal{L}_{depth} / \partial \widetilde{P}_s$ 。只考察这一尺度的直接融合路径：

$$d\mathcal{L}_{depth} = g_s^\top (W_{g,s} dG_s + W_{m,s} dS_s).$$

把每个微分前的系数转成列梯度，得到

$$\left. \frac{\partial \mathcal{L}_{depth}}{\partial G_s} \right|_{direct} = W_{g,s}^\top g_s, \quad \left. \frac{\partial \mathcal{L}_{depth}}{\partial S_s} \right|_{direct} = W_{m,s}^\top g_s. \quad (\text{S3})$$

$W_{m,s}$ 对应原计划 S3 的语义侧 W_s ；更换下标只是避免与尺度 s 重名。偏置不影响对 G_s 、 S_s 的导数。

11.5 粗尺度还有通往细尺度的梯度，不能漏掉

由 N7，G_s 不仅进入本尺度融合，还会影响 G_{s-1}。下式把完整特征图展平成向量，Jacobian 因而包含卷积和插值的跨像素依赖；W 的转置按各位置的 1×1 映射作用。将第 s 层分支的总梯度记为 g_G,s，使用链式法则：

g_{G,1} = W_{g,1}^T g_1, \quad g_{G,s} = W_{g,s}^T g_s + J_{G_{s-1},G_s}^T g_{G,s-1}, \quad s = 2, 3, 4.

第一项为本尺度直接融合；第二项为“先影响下一细尺度，再影响最终损失”。g_G,s-1 已包含它通往更细尺度的所有路径，因此递推逐层包含全部支路，不需要重复加同一路径。

语义支对深度损失同理。若考虑分割损失，令 g_seg,1=J_{a,S1}^T \nabla_a L_seg，则最细语义支总梯度增加 \lambda_seg g_seg,1，并继续沿 N7 向粗尺度传播。

共享 E_s 同时被几何分支、语义分支和更粗收缩路径使用，所以其输入梯度是所有这些路径的 Jacobian 转置乘对应梯度之和。共同特征 P_s 还具有直接残差到 \tilde{P}_s 的通路，也必须计入。

两任务梯度相加只是代数事实：当深度梯度与分割梯度内积为负时，它们可能相互抵消。能收到梯度不表示两任务必然互利。融合权重若全零，第一步到 G/S 的直接深度梯度也为零；融合权重自身仍可学习，后续才开放该路径。计划默认使用常规小随机初始化。

11.6 遵从计划的辅助监督与结构控制

控制	保持／改变什么	可以检验什么
C-noSeg	结构不变，\lambda_seg=0	是否依赖额外分割监督；第二支此时仅称特征支
C-noSemFuse	分割继续训练，移除 S_s \rightarrow 深度的显式融合	显式语义融合是否超过共享训练收益
C-noDPT	双分支保留，融合 /4 特征直接接共同 tail	末端多尺度 DPT 是否必要
A+Seg／B+Seg	同 mask、同 \lambda_seg、匹配 SegTail	C 是否超过一般辅助分割
C-match	缩窄 C，使含重组的读出总参与 A/B 约在 \pm 10\% 内	是否主要依赖额外容量

结构比较先用 A/B/C-noSeg；完整应用候选再比较 A+Seg、B+Seg、C。每个架构内的 1/2 配对辅助监督必须一致，尤其 C1/C2 只改变 \lambda_rel，而不额外给 C2 分割损失。

12. 计算与资源约束为什么影响理论实现

12.1 小参数更新不代表反向传播几乎没有成本〔R1〕

原计划最多使用 8 张 24GB RTX 3090。DDP 各卡持有模型副本并同步梯度，不能把 8×24GB 当成一个可任意使用的单卡 192GB 内存池。

以约 840M 参数计算，冻结骨干每参数占 2 bytes 时，纯权重大小为

$$\frac{840 \times 10^6 \times 2}{2^{30}} \approx 1.56 \text{ GiB.}$$

分子是参数个数乘每个参数的字节数，分母是每 GiB 的字节数。FP32 每参数 4 bytes，所以对应约 3.13GiB。它们都只算权重。

训练峰值要拆开记录：

$$M_{peak} \approx M_{frozen\ weights} + M_{trainable\ states} + M_{suffix\ activations} + M_{decoder\ activations} + M_{temporary} + M_{communication} \quad (R1)$$

这里是原计划的近似资源记账式。严格说，应在同一时刻 t 将互不重复的占用相加，再对 t 取最大值；不能把每类在不同时刻的独立峰值机械相加并称为精确实测。

若可训练参数、梯度、Adam 的两个状态都用 FP32，每参数对应 4+4+4+4=16 bytes，另有激活、缓存和框架开销。冻结骨干不保存这些优化器状态，但选中层之后仍需反传输入梯度，因而保留或重算 suffix 激活。

12.2 attention 二次复杂度与 query 抽样

一个 head 对 N 个 queries 和 N 个 keys 都计算概率，元素数为 N^2 。batch=1、20 heads、每元素 2 bytes，一层完整 attention 的存储为

$$M_A = 2 \times 20 \times N^2 \text{ bytes.}$$

N=773 时约 22.79MiB；若保存全部 32 层，仅该类矩阵约 0.71GiB，还没有计入 logits、梯度、QKV、前馈激活等。

图像高宽都放大两倍时，patch 数约增至 4 倍， N^2 约增至 16 倍。这是显式 attention 的二次增长来源。

关系损失只额外重算 k 个 heads、M 个抽中 queries 对全部 N keys 的 logits，元素数为 kMN。k=1、M=256、FP32 时：

$$4 \times 1 \times 256 \times 773 = 791552 \text{ bytes} \approx 0.755 \text{ MiB.}$$

M=256 来自透明最多 128 加背景最多 128。该节省只影响**额外关系监督张量**；正常深度前向仍是完整 attention，不是把模型变成稀疏网络。

12.3 正确冻结、梯度累积与预算换算〔R2〕

- 选中层之前无可训练参数，可用 no_grad 计算 prefix。
- 选中层、冻结 suffix 和读出必须保留 autograd，以训练 ϕ 、 ψ 。
- 教师构造用原 Q/K，在 no_grad 中完成，P 停止梯度。
- eval 关闭模型训练模式中的随机行为，不自动关闭梯度；requires_grad=False 冻结参数，不能代替对计算路径的判断。

若每卡微批量 b、卡数 n_GPU、梯度累积次数 a，则一次更新汇聚 $b \times n_{\text{GPU}} \times a$ 张图。原计划 $8 \times 1 \times 2 = 16$ ；4 卡时 $4 \times 1 \times 4 = 16$ 。微步 loss 除以 a 后累积，才对应相同的平均目标。

设完整 optimizer update 耗时 t_{step} 秒，总更新数为 T，则总墙钟训练时间约 $T t_{\text{step}}$ 秒。每一秒有 n_GPU 张卡工作，所以

$$\text{GPUh} = n_{\text{GPU}} \times T \times t_{\text{step}} / 3600. \quad (\text{R2})$$

除以 3600 是秒到小时的转换。假设完整 update 为 2 秒，8 卡跑 10,000 次更新， $\text{GPUh} = 8 \times 10000 \times 2 / 3600 \approx 44.44$ 。此处 2 秒仅为换算例子，不是 H/16+ 的实测速率。

这些推导保留“单层、少量 heads、冻结 prefix、必要时 checkpoint”的工程动机，但不能从参数量推断实际显存、吞吐或收敛。权重合并、SDPA 等价、混合精度和真实 3090 profile 仍需正式实现验收。

13. 让理论结论可被检验：六组对照与评价公式

13.1 原计划六组一项不少

以下第一主表固定 DPT，B 表示 DINOv3 B/16，H 表示 H/16+：

编号	可训练部分	损失
B0/H0	冻结骨干，训练 DPT 读出	深度
B1/H1	选定 Q/K LoRA+同读出	深度
B2/H2	与相应 1 组完全相同	深度+ FAR 关系

先为每个骨干／架构训练公共读出 T_0 ，再从同一预热 checkpoint 分叉。0/1/2 都继续训练相同 T_1 更新；最终 0 组不能只用更早的预热终点。原计划起点为 T_0 最多 20,000 次更新、 T_1 10,000 次更新，按 Dev 的收敛情况统一调整。

配对 1/2 需要锁定层、head、r、 η 、LoRA 初始因子、读出初始权重、数据顺序、图像增强、有效 batch、更新数、优化器、深度损失和 checkpoint 选择。FAR 额外 query 抽样使用独立随机流，不能消耗图像增强的随机流而破坏配对。

遵从原计划，发现种子 17 用于锁定位置、 β 和开发超参数；29、43 分别训练自己的 T_0 checkpoint，在各自的 0/1/2 分叉中共享并复用锁定位置，不重新使用 Confirm 选头。分叉时三组的 decoder optimizer 状态统一重置、学习率日程统一重启。

13.2 每个差分究竟隔离什么〔E1〕

令 e_X 表示模型 X 在同一测试域、同一规则下的透明 MAE，越小越好。把前一条件误差减去后一条件误差：

$$\begin{aligned}
 G_{\text{backbone}} &= e_{B0} - e_{H0}, \\
 G_{\text{LoRA}}^B &= e_{B0} - e_{B1}, & G_{\text{LoRA}}^H &= e_{H0} - e_{H1}, \\
 G_{\text{FAR}}^B &= e_{B1} - e_{B2}, & G_{\text{FAR}}^H &= e_{H1} - e_{H2}, \\
 I_{\text{scale} \times \text{FAR}} &= G_{\text{FAR}}^H - G_{\text{FAR}}^B.
 \end{aligned} \quad (\text{E1})$$

解释各行：

1. 第一行改变骨干规格，反映模型规模、深度、结构等综合差异，不能严格只归因于参数数量。
2. 第二行在相同骨干下打开 LoRA，衡量普通适配的增量。

3. 第三行保持 LoRA 与读出相同，仅增加关系监督，才是 FAR 主要增量证据。
4. 第四行再做差，比较这两套模型中 FAR 增量的不同，不自动推广为所有模型尺度的规律。

例如 H2 优于 H0，但 H2 与 H1 相当，只能说明适配有效，不能说明 FAR 关系监督必要。相对改善率 $(e_1 - e_2)/e_1$ 是把绝对改善除以原误差，要求 $e_1 > 0$ ；毫米差和百分比都应保留。

主检验遵从原计划：封存 Real-novel 上 H2 相对 H1 的透明 MAE 改善，同时背景、边界退化受控。Syn-novel、Real-known 完整报告。至少 3 个配对种子是计划要求，不等于已有结果。

13.3 跨三架构仍需各自的 1/2 配对

H-A0/1/2 就是 H0/1/2；增加 H-B0/1/2、H-C0/1/2，连同 B 的三组，共 12 个主配置。C 各组使用相同 λ_{seg} 。

这 12 个配置默认使用 A 上已经锁定的 H FAR 位置与 β ，迁移到 B/C，不能在 B/C 失败后悄悄重选头。各架构独立选头属于额外实验，需要同样的选择预算、新的确认安排，并重训相应 1/2 对照。

若各架构选头涉及多次确认检验，按计划预先拆分确认折，或采用 Holm 等多重比较校正，不能反复复用单一确认集却仍声称每次检验独立。

位置迁移、读出结构、分割监督、模型容量是不同实验因素。C 优于 A 不单独证明 FAR，也不自动证明双分支融合的独立作用。

13.4 MAE、RMSE 是怎样定义和聚合的〔E2〕

在某个预先确定的 GT 有效区域 Ω ，令残差 $r_p = \hat{Z}_p - Z_p^*$ ：

1. MAE 先取每个残差绝对值，再求算术平均。
2. RMSE 先平方残差，平均后开平方，以恢复深度单位。

$$MAE = \frac{1}{|\Omega|} \sum_{p \in \Omega} |\hat{Z}_p - Z_p^*|, \quad RMSE = \sqrt{\frac{1}{|\Omega|} \sum_{p \in \Omega} (\hat{Z}_p - Z_p^*)^2}. \quad (E2)$$

它们是评价定义，不是从模型结构推导出的性能定理。平方项使 RMSE 对较大误差更敏感。输入深度以米表示，输出毫米指标时两者都乘 1000：对于 RMSE，平方的 1000^2 在开根后回到 1000。

13.5 AbsRel 与 δ 阈值准确率〔E3〕

AbsRel 把绝对误差除以正 GT，再平均，从而衡量相对误差。阈值准确率先形成预测与 GT 的双向倍率，再判断是否小于 $t > 1$ ：

$$AbsRel = \frac{1}{|\Omega|} \sum_{p \in \Omega} \frac{|\hat{Z}_p - Z_p^*|}{Z_p^*}, \quad \delta_t = \frac{1}{|\Omega|} \sum_{p \in \Omega} 1 \left[\max \left(\frac{\hat{Z}_p}{Z_p^*}, \frac{Z_p^*}{\hat{Z}_p} \right) < t \right]. \quad (E3)$$

对于正深度，max 比值 $< t$ 等价于 $1/t < \hat{Z}/Z^* < t$ ，继续取 $\log$ 等价于 $|\log(\hat{Z}/Z^*)| < \log t$ 。它同时控制高估和低估的倍率误差。

原计划按 ClearGrasp 明确使用 $t \in \{1.05, 1.10, 1.25\}$ ，不能套用其他论文的默认阈值或相信不一致的历史表头。AbsRel 和 δ_t 无量纲。

13.6 为什么评价协议属于理论可信度的一部分

主表在 384×512 内容坐标去 padding 后一致评估；历史 144×256 协议另表。透明、背景和预定边界带分别报告，边界带默认向内外各扩 3 像素。所有有效域仅由 GT、mask 和固定范围确定。

主表明确遵从原计划：先逐图计算该区域指标，再在场景内对合法图像平均，最后对合法场景等权宏平均。令 m_I 表示一张图像的某个区域指标， G_{eff} 表示该指标有合法图像的场景集合， I_g 表示场景 g 内合法图像集合，则

$$m_g = \frac{1}{|I_g|} \sum_{I \in I_g} m_I, \quad m_{macro} = \frac{1}{|G_{eff}|} \sum_{g \in G_{eff}} m_g.$$

内层分母给场景内图像等权，外层分母给场景等权；某场景没有该区域有效图像时，不虚构一个零误差。补充表则可将所有有效像素的绝对误差相加，除以总像素数，得到 pooled MAE；pooled RMSE 将绝对误差改成平方误差，在总体平均后开根。

对于不同图像，逐图 RMSE 的平均不等于 pooled RMSE，因为平方根是非线性的。例如两张图像等大、每图均方误差分别为 0 和 4，平均逐图 RMSE=(0+2)/2=1，而 pooled RMSE= $\sqrt{(0+4)/2}=\sqrt{2}$ 。按场景宏平均也不等于按全部像素池化：前者给场景相同权重，后者给大区域更多权重。

测试不能用 GT 拟合尺度、平移、median ratio 或仿射。若预测含 NaN/Inf，要按预定规则报告失败和惩罚，不能删除困难像素后计算更低误差。

配对 bootstrap 应重抽真正独立的组。设共有 G 个独立组、每组误差差值为 d_g ，每次均匀有放回抽 G 个组索引，再平均抽中的 d_g ，形成重抽分布；取其第 5 百分位得到计划所用的近似单侧 95% 下界。把百万个相关像素当成独立样本会夸大证据。

多种子方差反映优化随机性，组 bootstrap 反映评估组变化，两者不可混成大量独立样本。跨种子平均误差也不等于先平均预测再评估的 ensemble。

13.7 主线与扩展数据的职责

训练与 Dev 来自合成训练来源；D_select/D_confirm 来自独立合成验证来源并分开职责；Syn-novel、Real-known、Real-novel 锁定后终评。相同场景、近邻视角、重复图与材质变体尽可能按组隔离。

GT 深度和 mask 可以用于训练教师、损失与 oracle，但不进入 RGB-only 测试函数。真实喷涂配对属于评估语境，不能被拿来启动主线跨材质教师。

机制消融也必须保留：

- $P=A^0$ 检验原关系保持正则是否足够。
- 纯 GT 核 $q_{ij} \propto \exp(-c_{ij})$ 保持相同 m 、补集与 β ，检验可靠集合内原 attention 偏好是否必要；它仍含原模型总质量信息。
- 空间核检验局部平滑解释。
- 置换**最终可靠概率值**保持全行熵与总质量，检验正确对应；打乱代价后重算不保证相同熵。
- 随机/末层头、去背景 KL、k/r 扫描检验定位、保持项和容量。

上述原关系、纯 GT 核、空间核等机制对照均获得同等 λ/β 开发预算，不能仅充分调优 FAR，再用未经适配的对照系数作因果归因。

这些对照界定论文能作出的归因，不是本文声称已经观察到的实验现象。

14. 原计划保留的跨材质扩展：独立推导与适用条件

14.1 它是独立扩展，不替换主线 GT 深度教师

本节只在额外取得**训练用、同几何、同相机、同照明**的透明／多种不透明材质配对时成立。改变材质但不改变表面与相机，首命中深度仍相同。它不使用封存真实测试中的喷涂配对来训练。

主线 P7 保持可靠总质量和补集逐项概率；本节跨材质混合没有自动继承这两项性质。两个教师要分别做最终 P 的 oracle，不能未经验证就直接叠加损失。

14.2 为什么多个 KL 教师可以先取概率平均〔X1-X2〕

固定透明图像的一行 query，有 J 张同几何不透明材质图，其对应冻结 attention 分布分别为 $A^{\{o,1\}} \dots A^{\{o,J\}}$ 。等权概率均值定义为

$$\bar{A}^o = \frac{1}{J} \sum_{j=1}^J A^{o,j}. \quad (X1)$$

因为每个教师非负、行和为 1，均值也非负且行和为 $(1/J) \times J=1$ 。均值是在**softmax 后的概率**上计算。

下面用 k 枚举 key，j 枚举材质， a_k 表示学生关系。对每项 log 比值插入平均教师：

$$\log \frac{A_k^{o,j}}{a_k} = \log \frac{A_k^{o,j}}{\bar{A}_k^o} + \log \frac{\bar{A}_k^o}{a_k}.$$

乘 $A_k^{\{o,j\}}$ ，对 key 求和，再对材质平均：

$$\begin{aligned} \frac{1}{J} \sum_j D_{KL}(A^{o,j} \| a) &= \frac{1}{J} \sum_j D_{KL}(A^{o,j} \| \bar{A}^o) \\ &\quad + \sum_k \left(\frac{1}{J} \sum_j A_k^{o,j} \right) \log \frac{\bar{A}_k^o}{a_k}. \end{aligned}$$

括号就是 X1 的均值，所以

$$\frac{1}{J} \sum_j D_{KL}(A^{o,j} \| a) = D_{KL}(\bar{A}^o \| a) + \frac{1}{J} \sum_j D_{KL}(A^{o,j} \| \bar{A}^o). \quad (X2)$$

第二项只依赖教师，与学生无关，所以使用均值教师和使用多个等权 KL 教师对学生具有相同梯度与最优点，但它们的损失数值差一个固定项。

平均 logits 后再 softmax 通常不同。若 $s^{\{j\}}$ 是 logits， $\text{softmax}((1/J) \sum s^{\{j\}})$ 的未归一化概率是 $\prod_j \exp(s^{\{j\}})^{(1/J)}$ ，对应几何型聚合；X1 是概率的算术均值，不能互换。

14.3 JS 分歧、上界及置信权重〔X3〕

把 X2 中与学生无关的第二项定义为等权 Jensen–Shannon 分歧：

$$JS_i = \frac{1}{J} \sum_j D_{KL}(A_i^{o,j} \parallel \bar{A}_i^o).$$

下界 $JS_i \geq 0$ 直接来自 KL 非负。上界可以逐项证明：由概率均值，

$$\bar{A}_{i,k}^o = \frac{1}{J} \sum_{\ell} A_{i,k}^{o,\ell} \geq \frac{1}{J} A_{i,k}^{o,j}, \implies \log \frac{A_{i,k}^{o,j}}{\bar{A}_{i,k}^o} \leq \log J.$$

对 k 乘 $A_{i,k}^{o,j}$ 后求和，右侧是 $\log J \times \sum_k A_{i,k}^{o,j} = \log J$ ；对 j 平均仍不超过 $\log J$ 。因此 $0 \leq JS_i \leq \log J$ 。

等价的熵式也可由展开验证。定义概率熵 $H(p) = -\sum_k p_k \log p_k$ ，整理 JS 中的两项：

$$JS_i = H(\bar{A}_i^o) - \frac{1}{J} \sum_j H(A_i^{o,j}).$$

第一项来自 $-\sum_k [(1/J) \sum_j A_{i,k}^{o,j}] \log \bar{A}_{i,k}^o$ ；第二项来自各教师 $\sum A \log A$ 的平均。

当 $J \geq 2$ ，用 $\log J$ 归一化分歧，定义一致性系数 s_i 。再令 $t_i \in \{0,1\}$ 表示可靠透明 query 指示：

$$s_i = \text{clip} \left(1 - \frac{JS_i}{\log J}, 0, 1 \right), \quad P_i^{\text{opaque}} = (1 - \beta t_i s_i) A_i^0 + \beta t_i s_i \bar{A}_i^o. \quad (\text{X3})$$

clip 将浮点误差等导致的越界截回 $[0,1]$ 。在精确算术下 JS 已满足区间，系数自然处于 $[0,1]$ ，故 P^{opaque} 是合法凸组合。 $t_i=0$ 或 $s_i=0$ 时恢复原关系； $JS=0$ 时所有教师相同， $s_i=1$ 。

$J=1$ 时 $\log J=0$ ，不能除以它，只能另行约定 $s_i=1$ ，且不得宣称已测出跨材质一致性。

一致不等于正确。 所有教师都均匀时 $JS=0$ ，但不说明几何关系准确。因此需保留固定 $s=1$ 、单 donor、错误几何 donor、key 置换等控制。还要对普通适配开放相同额外数据访问，否则收益可能来自新增训练图像本身。

14.4 背景外观鲁棒性的漂移指标 (X4)

取同几何同相机、只改变背景纹理或照明的 V 张受控图像；此处 V 是图像数量，不是 attention 的 value 矩阵。对应像素预测为 $\hat{Z}_p^{(v)}$ 。先计算均值

$$\bar{Z}_p = \frac{1}{V} \sum_{v=1}^V \hat{Z}_p^{(v)}.$$

再计算每张预测偏离均值的平方，平均后开根，得到该像素跨外观条件的标准差；最后在透明区域平均：

$$Drift = \frac{1}{|\Omega_T|} \sum_{p \in \Omega_T} \sqrt{\frac{1}{V} \sum_{v=1}^V (\hat{Z}_p^{(v)} - \bar{Z}_p)^2}. \quad (\text{X4})$$

V 作分母表示描述这一组受控条件的总体波动，不是以 $V-1$ 构造无偏样本方差估计。它和深度有相同单位。

$Drift=0$ 只表示不同外观下预测相同，常数深度也能做到，因此必须同时报告每张图的真实 MAE。还需单独改变距离、尺寸、曲率，并检查相应 GT 变化是否被预测捕捉，才能区分外观鲁棒性与对所有变化都不敏感。

例如具有明确对应的两种距离条件，可比较

$$\left|(\hat{Z}^{(2)} - \hat{Z}^{(1)}) - (Z^{*,(2)} - Z^{*,(1)})\right|.$$

它先计算预测变化，再减真实变化、取绝对值。形变没有可靠像素对应时，不能直接把同一二维坐标当成同一物理点，应使用渲染对应或逐图 GT 评价。

14.5 “更接近背景”比例的数学含义〔X5〕

若额外渲染了无物体场景，令 Z_{bg} 为该背景深度， Z_f 为含透明物体时的首表面深度。在预定 $|Z_{bg}-Z_f|>\tau$ 的合法区域评价， $\tau>0$ 是预先固定的深度分离阈值，避免两个目标几乎重合。

逐像素比较预测距背景和首表面的距离，再平均指示函数：

$$R_{bg} = \text{mean } 1 \left[\left| \hat{Z} - Z_{bg} \right| < \left| \hat{Z} - Z_f \right| \right]. \tag{X5}$$

例如 $Z_{bg}>Z_f$ ，两边距离非负，可以平方保持不等号：

$$(\hat{Z} - Z_{bg})^2 < (\hat{Z} - Z_f)^2.$$

展开并抵消 $\hat{Z}^2$ ：

$$-2\hat{Z}Z_{bg} + Z_{bg}^2 < -2\hat{Z}Z_f + Z_f^2 \Rightarrow 2\hat{Z}(Z_{bg} - Z_f) > Z_{bg}^2 - Z_f^2.$$

将右边因式分解为 $(Z_{bg}-Z_f)(Z_{bg}+Z_f)$ ，除以正数 $2(Z_{bg}-Z_f)$ ，得到 $\hat{Z}>(Z_{bg}+Z_f)/2$ 。可见该指标本质是在两种候选深度之间比较邻近关系，不能证明模型沿真实折射光路预测。

没有额外背景 GT 就不能计算该指标；透明场景原始传感器深度不能自动代替 Z_{bg} 。

15. Double check：与原计划一致性、推导正确性与实际证据

15.1 原公式逐项覆盖表

原计划位置／公 式	本文位置	核验内容
§ 2, G1-G4	§ 1	针孔射线、首命中、range→Z、简化透明成像；区分定义与物理近似
§ 4, A1-A4	§ 2、§ 8.8	QKV、实际 RoPE 次序、完整 softmax、多头输出与两次残差
§ 5, P1	§ 3.1-3.2	可靠 patch、log 比例、平方尺度、截断；不把同深度等同同物体
§ 5, P2-P6	§ 3.3-3.6	条件质量、约束优化、拉格朗日导数、归一化、唯一最优解
§ 5, P7-P8	§ 3.7-3.9	补集保持、可靠质量保持、混合、下界、退化情况与数值例子
§ 5, P9	§ 4	二元质量 KL+两部分条件 KL，不能裁 key
§ 6, D1-D2	§ 5	固定读出干预、组平均收益、独立确认、多头交互
§ 7, M1-M6	§ 6	Q/K 因子化、参数量、局部精确差、初始化、权重合并

§ 8, L1–L3	§ 7.1–7.3	正米制输出、log-Huber、区域平衡及尺度敏感性
§ 8, L4–L5	§ 7.4–7.5	全 key KL、停止梯度、均匀抽 query 的无偏性
§ 8, L6–L9	§ 8	KL／深度两条梯度链、RoPE 逆向、LoRA 因子、softplus 梯度
§ 9, B1–B4	§ 9	Pinsker 常数、加权条件均值、无 RoPE 与实际 RoPE 秩界、单头必要条件
§ 10, N1–N9	§ 10	四尺度真实重组、A/B/C 完整数据流、共同 tail、C 后置 DPT
§ 11, S1–S3	§ 11	平衡 BCE、总损失、直接与跨尺度总梯度、辅助监督控制
§ 12–13, R1–R2	§ 12、 § 13.1	显存分项、梯度路径、query 存储、累积与 GPU-hours、严格分叉
§ 14, E1	§ 13.1–13.3	六组与增益差分、12 配置、位置迁移和严格配对
§ 15, E2–E3	§ 13.4–13.6	指标单位、 δ 阈值、宏平均、失败处理与统计区间
§ 17, X1–X3	§ 14.1–14.3	跨材质均值 KL 恒等式、JS、置信混合及独立扩展条件
§ 17, X4–X5	§ 14.4–14.5	外观漂移、几何敏感性、背景邻近比例及其解释限度

未把原计划的排程、相关工作综述和所有运行参数逐段搬入正文；这些不属于本次提炼的理论主体。涉及理论结论的训练／测试边界、实验控制和计算条件均保留。模型事实沿用原计划锁定的代码版本，不把后续潜在实现改动混入推导。

机器核对确认：原计划的 **60 组编号公式全部覆盖，编号无重复、无遗漏**；全文公式块分隔符、花括号和环境配对通过检查，本地引用路径均存在。记录见 [文档完整性检查](#)。这些格式检查只验证文档结构，不代替下一节的数学复核。

15.2 对方法定义的逐项确认

计划要求	本文确认
单 RGB → 米制前表面光轴深度	保留；相机内参只用于任务解释与标签核验，不新增为模型测试输入
H/16+ 主骨干、B/16 规模对照	保留真实配置与两组读出层位
一个 block、默认一个 head、 $r=4$ 、 $\eta=1$	保留；两个 heads 或其他秩作为单独验证
只训练读出和选中 Q/K LoRA	保留；原 V 与其他骨干参数冻结
GT 深度重加权原 attention	保留原条件偏好，不擅自换成纯 GT 核或全 logits 减代价
可靠总质量及补集概率保持	完整证明；不能只在可靠 keys 内蒸馏

先 oracle，再 RGB 学生	保留；oracle 不冒充部署表现或严格性能上界
完整 keys、可抽 query	保留，给出抽样无偏推导及完整 key 梯度
三架构定义	保留 A：DPT；B：U-Net；C：共享收缩+双扩张+融合+DPT
C 使用平衡 BCE 辅助分割	保留；无 Dice、硬 GT mask 门控或新增中间深度
H2 对 H1、B2 对 B1	保留相同参数、预算、初始化、数据和辅助监督
测试与训练标签隔离	保留合成训练／选择／确认与封存测试职责
跨材质教师与受控渲染	保留为独立扩展，不成为主线启动依赖
不先集中罗列变量	全文变量在当前公式或紧邻段落中首次解释

15.3 本次实际完成的双重复核

第一层：逐式代数与语义审查。 主稿写作时逐步展开，并由独立审查核对概率优化、梯度、秩界，以及架构、损失与实验协议。未发现需要改变原计划主路线的代数错误。关键成立条件已在相应正文说明，不能省略后仍作同样结论。

第二层：实际重跑的小张量数值检查。 本次重新运行原 33 项检查，并新增 39 项，合计 **72 项全部通过**。它们采用 NumPy float64 合成张量和固定随机种子，不依赖已完成的真实训练。

检查集合	实际结果	最大绝对误差
原 FAR 数学核验脚本重新运行	33／33 通过	$1.3907059254 \times 10^{-9}$
新增理论与全梯度链核验	39／39 通过	$3.1802960265 \times 10^{-10}$

原 33 项覆盖教师合法性、质量保持、Gibbs 恒等式、完整 key KL、关系梯度、含 RoPE 的四组 LoRA 因子梯度、合并、局部残差、抽样和 log-Huber 等。

新增 39 项包括：

- 本文完整教师手算例子：5 项。
- 深度项经固定下游、AV、softmax、RoPE、Q/K 到 LoRA 的全链：12 项，其中 10 组有限差分梯度。
- 平衡 BCE 及仅一类存在时的归一化：4 项。
- C 两尺度分支的直接与总梯度：4 项。
- 加权条件 KL 最优性恒等式：4 项。
- 跨材质 KL／JS 分解、熵与上下界：6 项。
- RoPE 秩反例：4 项。

有限差分以 $[L(\theta+h)-L(\theta-h)]/(2h)$ 近似导数，再与解析梯度比较；它提供独立于手工推导的数值交叉验证，但有限例子不取代上面的证明。较大的相对误差也可能来自真梯度接近零，所以报告采用预先给定容差下的绝对误差。

可复核文件：

- [原核验脚本](#) 与 [本次重跑结果](#)。
- [新增核验脚本](#) 与 [新增结果](#)。
- [独立数学审查](#) 与 [架构／计划范围审查](#)。

15.4 哪些是澄清，哪些没有被“证明”

这次展开补充了以下严谨表述，没有改换方法：

1. P3 是 KL 正则兼容性优化，P1 是任务偏好；二者不是真实几何关系的无误标签。
2. 深度项通过 softmax Jacobian 反传，不能用关系项 a-p 替代全部梯度。
3. M4 只对单一适配层、确定性相同输入下的当前 attention 子层成立。
4. B1 只约束当前固定 V 的局部输出；不能扩大为最终背景误差保证。
5. B3 的小秩打分界只用于无 RoPE 简化情形，真实模型使用更一般界。
6. S3 是直接梯度，粗尺度必须增加向细尺度传播的路径。
7. X3 跨材质教师不继承 P7 的可靠质量与补集保持。
8. R1 是同一时刻占用分项的近似记账，不是不同张量峰值之和的精确预测。

尚未完成且不能由本文宣称完成的，是：真实 DINOv3 算子集成、实际 checkpoint 合并误差、ClearGrasp 标签验收、训练收敛、三种读出精度、3090 显存与吞吐、FAR 在真实域的增益。它们保留为原计划的实施和实验验收。

15.5 提炼后的论文核心论点

FAR 要检验的是：在冻结视觉表示中，用首表面任务收益验证一小部分可干预关系，再用 GT 深度构造保留原关系结构的温和教师，能否通过紧凑 Q/K 适配，在单 RGB 部署、相同模型容量与训练条件下，获得超过普通 LoRA 的深度收益。

本文已经给出这个研究命题所需的任务定义、教师最优解、概率约束、完整梯度、表达边界与三架构接口。命题是否为真，最终仍由原计划规定的严格对照和封存测试回答。